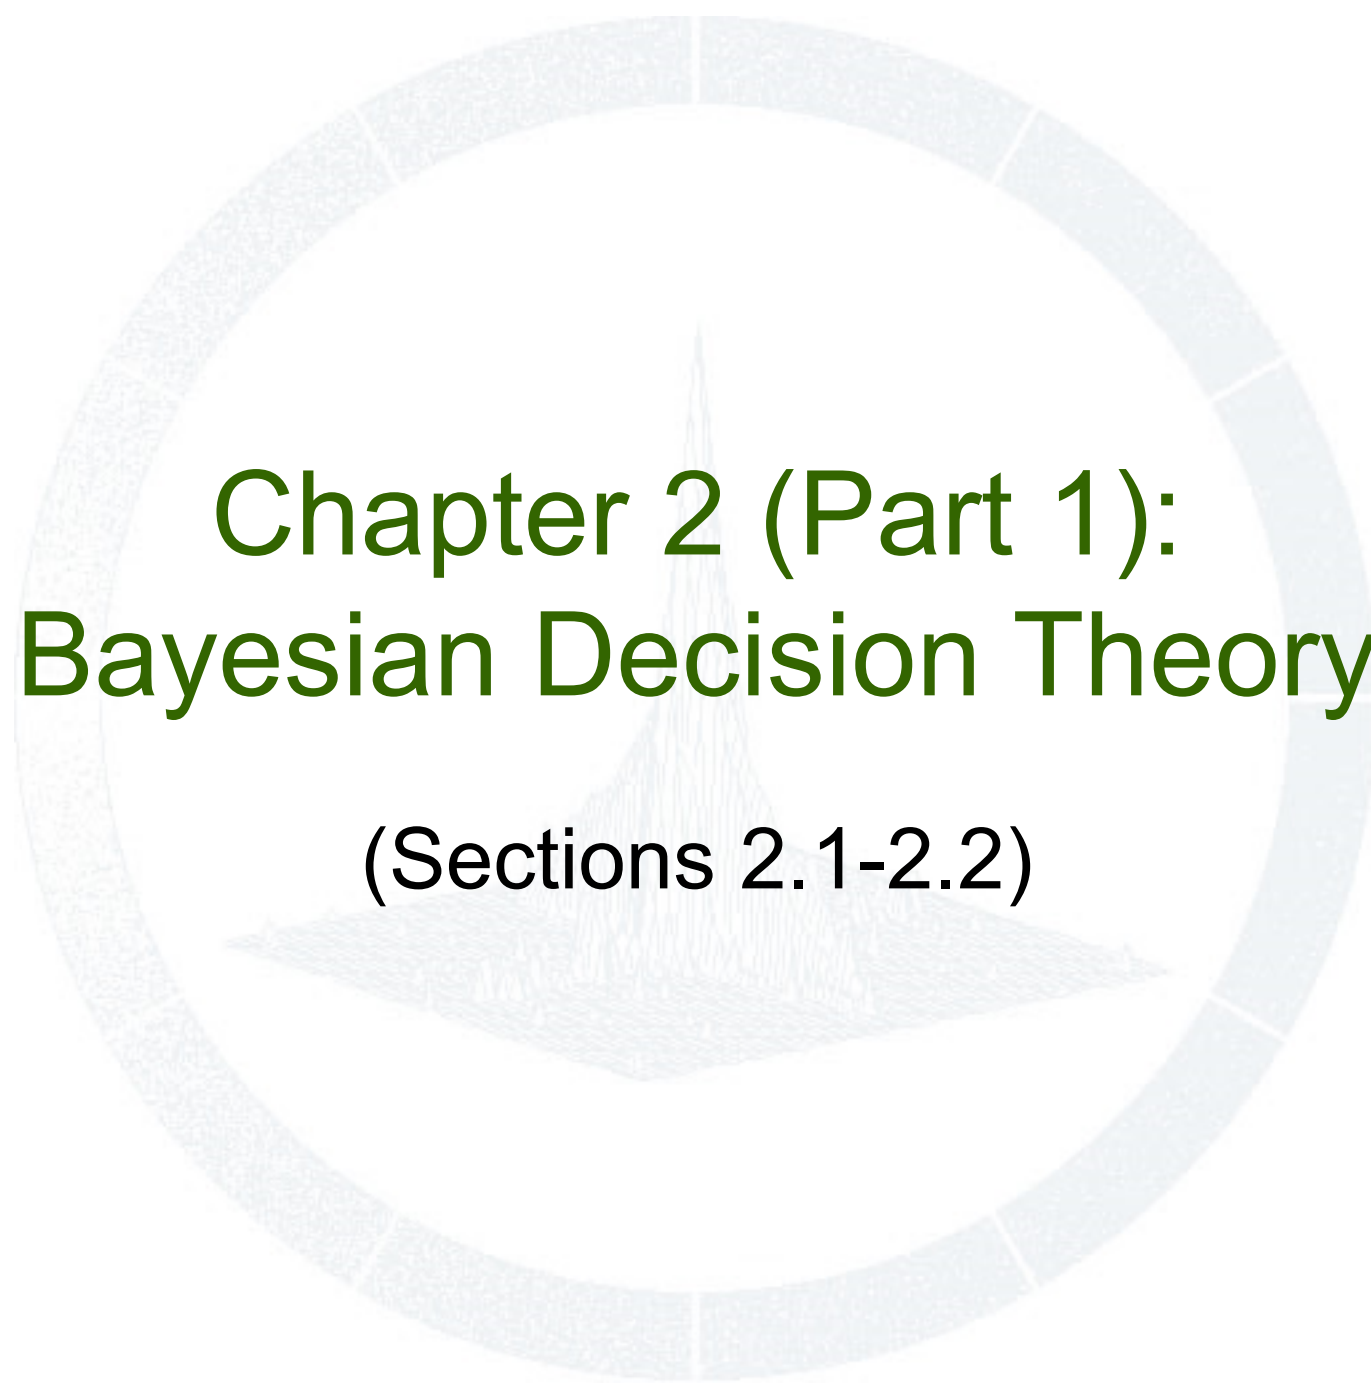




# 模式识别的理论与方法

## Pattern Recognition

裴继红



# Chapter 2 (Part 1): Bayesian Decision Theory

(Sections 2.1-2.2)

# 概率、条件概率、联合概率

- 概率
- 条件概率
- 联合概率



# Introduction

- 鲈鱼/鲑鱼的例子
  - 类别状态, 先验的(prior)

类别状态是一个随机变量

- 假设捕获的鲈鱼和鲑鱼数量是等概率的

$$P(\omega_1) = P(\omega_2) \quad (\text{等先验概率})$$

$$P(\omega_1) + P(\omega_2) = 1 \quad (\text{排他性、穷尽性})$$



# 基本概念

- 类别状态.

令  $\omega$  表示类别状态. 则  $\omega$  是一个随机变量.

(例如: 对鲈鱼  $\omega = \omega_1$ , 对鲑鱼  $\omega = \omega_2$ )

- 先验概率.

令  $P(\omega_1)$  和  $P(\omega_2)$  分别表示  $\omega_1$  和  $\omega_2$  的先验概率.



# 简单决策规则

- 决策规则

在只有先验信息的条件下.

若 $P(\omega_1) > P(\omega_2)$ ，则归类为  $\omega_1$ ; 负责归类为  $\omega_2$

但是，一般来说上述决策规则会出现大量错误 ....



# 条件信息

- 使用类条件信息
  - 类条件概率 $P(x | \omega_1)$  和  $P(x | \omega_2)$  描述了不同的类别（鲈鱼和鲑鱼）中的个体在亮度（lightness）分布上的差异



# 类条件概率密度函数

令  $x$  是一个连续的随机变量,  
 $p(x | \omega)$  是给定类别  $\omega$  后  $x$  的概率密度.

例如, 在给定类别为鲑鱼类时, 该类别中亮度不同的鱼的概率分布记为:

$$p(\text{lightness} | \text{salmon}) ?$$


或者, 在给定类别为鲈鱼类时, 该类别中亮度不同的鱼的概率分布记为:

$$p(\text{lightness} | \text{sea bass}) ?$$





# 条件概率密度函数



- 类条件概率密度函数（**class-conditional probability density functions**）表示的是在类  $\omega_i$  中，给定的特征测量值为  $x$  的模式的概率密度。
- 若  $x$  表示鱼的亮度, 上图的两条曲线可以描述两类鱼在不同亮度下的比例。
- 在规范化的密度函数中，每条曲线下的面积都是 1.0.



# 后验，似然概率，证据

## Posterior, likelihood, evidence

$$P(\omega_j | x) = P(x | \omega_j) P(\omega_j) / P(x)$$

在两类情况下

$$P(x) = \sum_{j=1}^2 P(x | \omega_j) P(\omega_j)$$

$$\textit{Posterior} = (\textit{Likelihood} \cdot \textit{Prior}) / \textit{Evidence}$$



# 贝叶斯公式 (Bayes Formula)

如何使用先验、类条件密度获得类别状态的概率?

**Bayes 公式.**

$$P(\omega_j|x) = \frac{p(x|\omega_j)P(\omega_j)}{p(x)}$$

Diagram illustrating the components of Bayes' Formula:


- likelihood** points to  $p(x|\omega_j)$
- prior probability** points to  $P(\omega_j)$
- evidence** points to  $p(x)$
- posterior probability** points to  $P(\omega_j|x)$

**Bayes 决策:**

若  $P(\omega_1|x) > P(\omega_2|x)$  , 则决策为  $\omega_1$  , 否则决策为  $\omega_2$



# 后验概率（Posterior probabilities）



- 如图Fig. 2.1所示是先验（priors）概率分别为 $P(\omega_1) = 2/3$ 和 $P(\omega_2) = 1/3$ 时，计算出的后验概率密度（Posterior probabilities）的曲线。
- 在这种情况下，若一个模式的特征测量值为  $x=14$ ，则该模式在类 $\omega_2$ 中的概率约为 0.08，在 $\omega_1$ 中的约为 0.92。对每个  $x$ ，后验概率之和为 1.0



# Bayes 决策

决策是由后验概率给出的,  
 $x$  是一个观测数据:

若  $P(\omega_1 | x) > P(\omega_2 | x)$   $\longrightarrow$  True 类状态 =  $\omega_1$

若  $P(\omega_1 | x) < P(\omega_2 | x)$   $\longrightarrow$  True 类状态 =  $\omega_2$

这样:

当我们观测到一个特定  $x$  时, 决策的错误概率为:

$P(error | x) = P(\omega_1 | x)$  , 如果决策为  $\omega_2$

$P(error | x) = P(\omega_2 | x)$  , 如果决策为  $\omega_1$



# Bayes 规则的简化

**Bayes 公式.**

$$P(\omega_j|x) = \frac{p(x|\omega_j)P(\omega_j)}{p(x)}$$

证据  $p(x)$  对所有类别状态都是相同的，在决策时可以省略。

规则:

若  $P(x|\omega_1)P(\omega_1) > P(x|\omega_2)P(\omega_2)$  判定为类别  $\omega_1$ ，否则为  $\omega_2$

分析:

若  $P(x|\omega_1) = P(x|\omega_2)$  则决策只依赖于先验概率.

若  $P(\omega_1) = P(\omega_2)$  则决策只依赖于似然概率.



# 最小化错误概率

- 最小化错误概率

若  $P(\omega_1 | x) > P(\omega_2 | x)$  时，决策为  $\omega_1$  ；  
否则决策为  $\omega_2$

因此：

$$P(error | x) = \min [P(\omega_1 | x), P(\omega_2 | x)]$$

(Bayes decision)



# 错误概率

什么是错误概率？

$$P(\text{error}|x) = \begin{cases} P(\omega_1) & \text{if we decide } \omega_2 \\ P(\omega_2) & \text{if we decide } \omega_1 \end{cases}$$

Bayes 规则可以使错误概率最小化吗？

$$P(\text{error}) = \int_{-\infty}^{\infty} P(\text{error}, x) dx = \int_{-\infty}^{\infty} P(\text{error}|x) p(x) dx$$

如果对每一个  $x$  我们都使错误最小化

$P(\text{error}|x)$  是否可以尽可能小？

回答是 “yes”.





# 贝叶斯决策理论 – 连续特征情况

对前面的决策思想进行一般化

- ① 特征的数量可使用一个以上
- ② 类别状态的数量可用于两类以上
- ③ 不仅仅做出类别状态的决策，可以允许采取某种行为
- ④ 引入损失函数（**loss of function**）比使用错误概率（**probability of error**）更具有一般性



# 贝叶斯决策理论 – 连续特征情况

- 允许采取某种行动，而不仅仅只是分类
  - 首先，要允许拒识的可能性

即在近似或坏的情况下，拒绝做出决策!



# 损失函数 ( Loss Function )

损失函数规定了在采取每一种行为时需要付出的代价

令

$\{\omega_1, \omega_2, \dots, \omega_c\}$  是具有个  $c$  类的类状态集合

令

$\{\alpha_1, \alpha_2, \dots, \alpha_a\}$  是可能采取的行为集合

令  $\lambda(\alpha_i | \omega_j)$  是类状态为  $\omega_j$  时, 采取行为  $\alpha_i$  而引起的损失



# 条件风险 (Conditional Risk)

总风险

$$R = \text{Sum of all } \underbrace{R(\alpha_i | x)}_{\text{Conditional risk}} \text{ for } i = 1, \dots, a$$

**Conditional risk**

最小化 **R**  $\longleftrightarrow$  最小化  $R(\alpha_i | x)$  for  $i = 1, \dots, a$

$$R(\alpha_i | x) = \sum_{j=1}^c \lambda(\alpha_i | \omega_j) P(\omega_j | x)$$

for  $i = 1, \dots, a$



# Bayes 风险决策

选择行为 $\alpha_i$ ，使得风险  $R(\alpha_i | x)$  为最小，即

→  $R$  是最小的

在这种情况下的  $R$  称为**贝叶斯风险**（**Bayes risk**）  
= 等价于所能得到的**最好的性能**！



# 损失函数小结

令  $\{\omega_1, \omega_2, \dots, \omega_c\}$  是可能的类状态.

令  $\{a_1, a_2, \dots, a_k\}$  是可能的行为.

## 损失函数

$\lambda(a_i|\omega_j)$  是类状态为  $\omega_j$  时采取行为  $a_i$  引起的损失

假设我们观测到了一个特定的  $x$ ，考虑采取行为  $a_i$ .

如果真实的类状态是  $\omega_j$ ，则损失为  $\lambda(a_i|\omega_j)$

期望损失  $R(a_i|x) = \sum_j \lambda(a_i|\omega_j) P(\omega_j|x)$

(这也称为条件风险.)

**决策:** 选择使条件风险最小化的行为  
(\*\*可能的最好性能\*\*)



# 两类时的风险决策问题

## 假设

$\alpha_1$  : 在类别为  $\omega_1$  时采取的行为

$\alpha_2$  : 在类别为  $\omega_2$  时采取的行为

$\lambda_{ij} = \lambda(\alpha_i | \omega_j)$  当真实状态为  $\omega_j$  , 决策为状态  $\omega_i$  而引起的损失

## 条件风险:

$$R(\alpha_1 | x) = \lambda_{11}P(\omega_1 | x) + \lambda_{12}P(\omega_2 | x)$$

$$R(\alpha_2 | x) = \lambda_{21}P(\omega_1 | x) + \lambda_{22}P(\omega_2 | x)$$



# 两类问题的决策

规则如下:

若  $R(\alpha_1 | x) < R(\alpha_2 | x)$

则采取行为  $\alpha_1$ : 此时做出的“决策为  $\omega_1$ ”

与上述规则等价的规则为:

决策为  $\omega_1$ , 若:

$$(\lambda_{21} - \lambda_{11}) P(x | \omega_1) P(\omega_1) > (\lambda_{12} - \lambda_{22}) P(x | \omega_2) P(\omega_2)$$

否则, 决策为  $\omega_2$





## 两类情况

对该问题的另一种描述如下.

决策为  $\omega_1$ ，若

$$\frac{p(x|\omega_1)}{p(x|\omega_2)} > \frac{(\lambda_{12} - \lambda_{22})}{(\lambda_{21} - \lambda_{11})} \frac{p(\omega_2)}{p(\omega_1)}$$

## likelihood ratio

constant

描述为:

决策为  $\omega_1$ ，如果似然比大于一个给定的阈值。

注意: 该阈值独立于观测量  $x$ .



# 似然比 (Likelihood ratio)

前述规则等价于下面的规则:

$$\text{if } \frac{P(x/\omega_1)}{P(x/\omega_2)} > \frac{\lambda_{12} - \lambda_{22}}{\lambda_{21} - \lambda_{11}} \cdot \frac{P(\omega_2)}{P(\omega_1)}$$

则采取行为  $\alpha_1$  (此时决策为  $\omega_1$ )

否则采取行为  $\alpha_2$  (此时决策为  $\omega_2$ )

## 最优决策

若似然比大于一个独立于输入模式  $x$  的阈值, 则决策为  $\omega_1$  是最优决策

