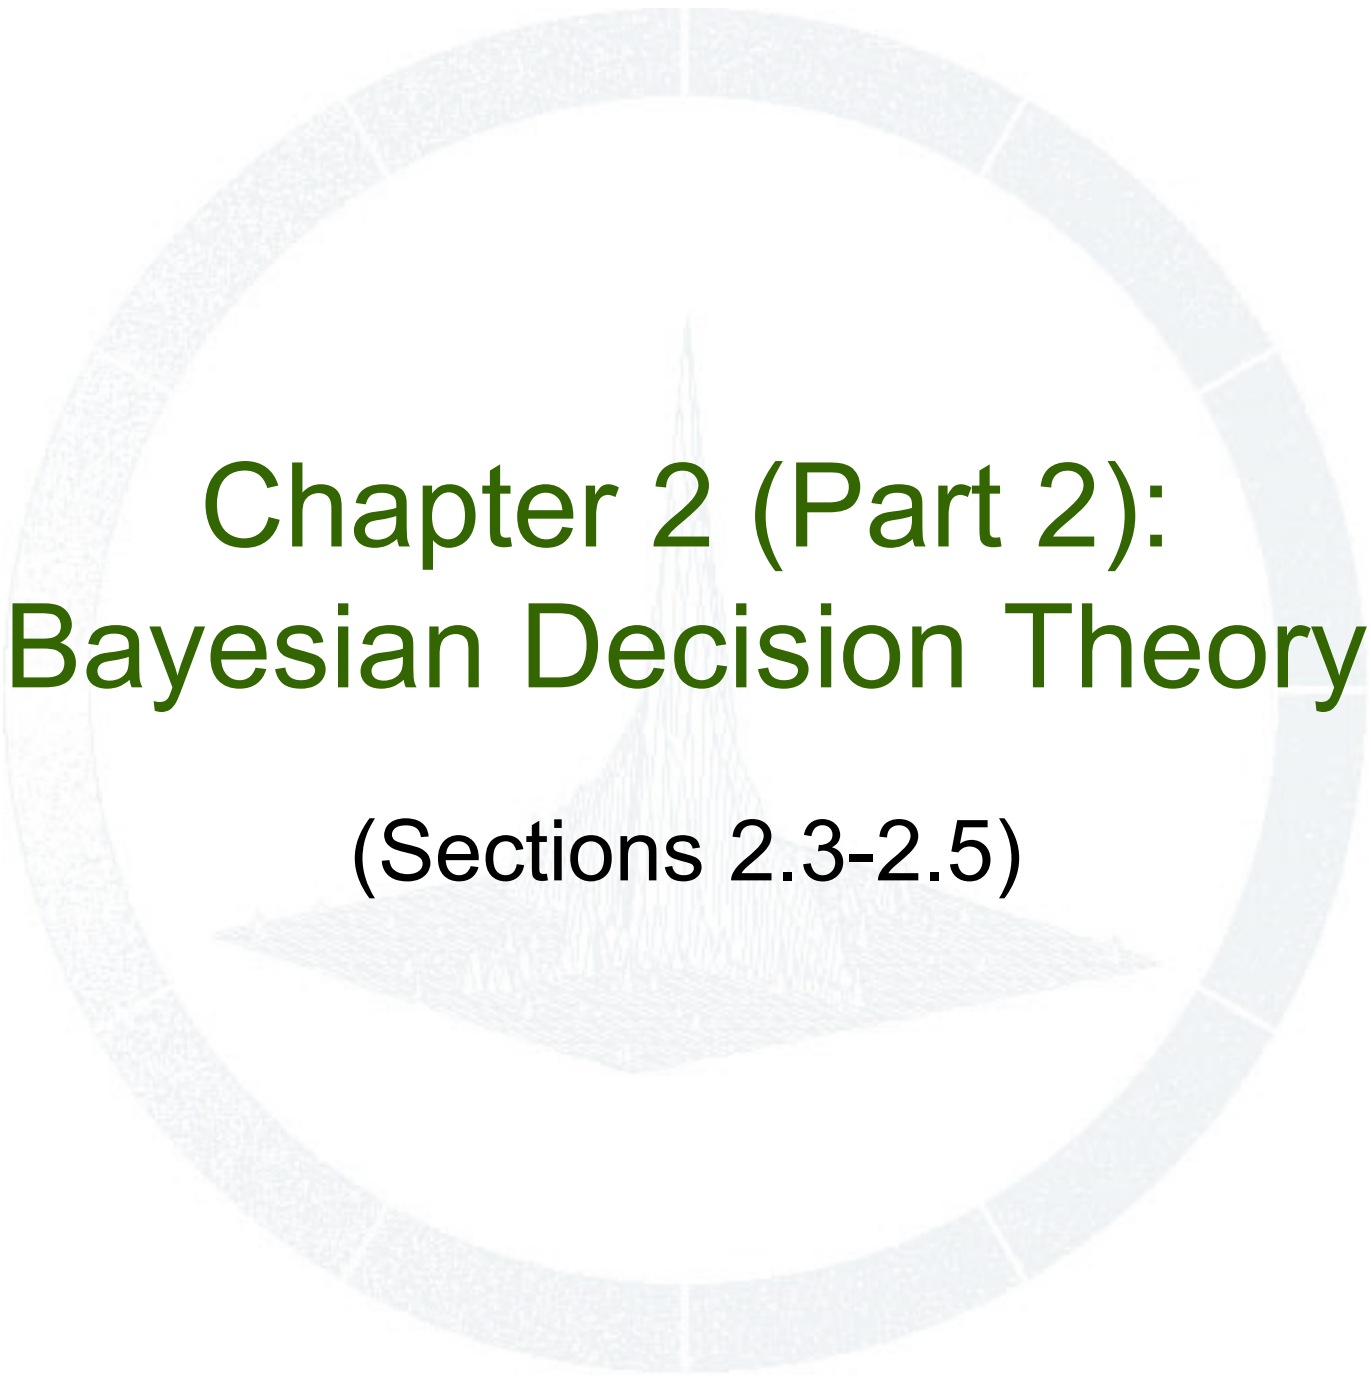




# 模式识别的理论与方法

## Pattern Recognition

裴继红



# Chapter 2 (Part 2): Bayesian Decision Theory

(Sections 2.3-2.5)

# 本讲内容

- 最小化错误率分类
- 分类器, 判别函数, 及决策面
- 正态密度



# 最小化错误率分类

## Minimum-Error-Rate Classification

行为是在类别决定之后的决策

若采取行为  $\alpha_i$ ，而真实状态是  $\omega_j$  则：

若  $i = j$ ，决策正确；相反，

若  $i \neq j$ ，决策错误。

目标是找到一个决策规则，可以最小化错误概率  
(*probability of error*，或称错误率 *error rate*)，



# 0-1损失函数 (zero-one loss function)

- 考虑下面的对称0-1损失函数:

$$\lambda(\alpha_i, \omega_j) = \begin{cases} 0 & i = j \\ 1 & i \neq j \end{cases} \quad i, j = 1, \dots, c$$

由此, 条件风险为:

$$\begin{aligned} R(\alpha_i | x) &= \sum_{j=1}^{j=c} \lambda(\alpha_i | \omega_j) P(\omega_j | x) \\ &= \sum_{j \neq i} P(\omega_j | x) = 1 - P(\omega_i | x) \end{aligned}$$

相应于该损失函数的风险是平均概率误差



## 0-1损失 ( Zero-One Loss )

- 最小化风险要求最大化  $P(\omega_i | x)$

因为  $R(\alpha_i | x) = 1 - P(\omega_i | x)$

- 对于最小化错误率

若  $P(\omega_i | x) > P(\omega_j | x) \quad \forall j \neq i$ , 则决策为  $\omega_i$  。



## 0-1损失

0-1函数的决策区域

$$\text{Let } \frac{\lambda_{12} - \lambda_{22}}{\lambda_{21} - \lambda_{11}} \cdot \frac{P(\omega_2)}{P(\omega_1)} = \theta_\lambda \text{ then decide } \omega_1 \text{ if : } \frac{P(x/\omega_1)}{P(x/\omega_2)} > \theta_\lambda$$

若  $\lambda$  是0-1损失函数，即意味着：


$$\lambda = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}$$

$$\text{then } \theta_\lambda = \frac{P(\omega_2)}{P(\omega_1)} = \theta_a$$

$$\text{if } \lambda = \begin{pmatrix} 0 & 2 \\ 1 & 0 \end{pmatrix} \text{ then } \theta_\lambda = \frac{2P(\omega_2)}{P(\omega_1)} = \theta_b$$



# 最小损失似然率决策示意图



图Fig. 2.1显示出了似然率 $p(x|\omega_1)/p(x|\omega_2)$ 的分布。

- 若采用0-1损失分类, 决策边界由阈值 $\theta_a$ 确定。若将 $\omega_2$ 误分类为 $\omega_1$ 时的损失比将 $\omega_1$ 误分类为 $\omega_2$ 时的损失大, 可以通过将阈值调整为较大的 $\theta_b$ , 这样可使 $R_1$ 的区间变小。





# 模式分类器：Pattern Classifier

## 如何表示一个模式分类器？

最常用的方法是通过判别函数（**discriminant functions**）：  
若用  $\{\omega_1, \omega_2, \dots, \omega_c\}$  标记可能的类别状态。

对每一个类，建立一个判别函数  $g_i(x)$

分类器是将样本指派一个到类  $\omega_i$ ，若

$$g_i(x) > g_j(x) \quad \text{for all } j \neq i$$

- 因此，分类器（**classifier**）是可以计算个  $c$  个判别函数的一个网络（**network**），或者一个机器（**machine**）



# 判别函数：Discriminant Functions

- 对多类别情况

判别函数集合：

$$g_i(x), \quad i = 1, \dots, c$$


分类器将特征向量  $\mathbf{x}$  指派到类  $\omega_i$

若：

$$g_i(x) > g_j(x) \quad \forall j \neq i$$



# 模式分类器



具有 $d$ 个输入和 $c$ 个判别函数 $g_i(\mathbf{x})$ 的统计模式分类器的函数结构

- 后续的步骤是对最大判决值进行决策，并将输入分类到对应模式类中。  
箭头表示了信息流的方向。



# 判别函数的简化

注意：假设  $f(\cdot)$  是一个单调增函数(monotonically increasing function), 则将所有  $g_i(x)$  替换为  $f(g_i(x))$  时, 可以得到相同的决策结果。

对应地:

$$g_i(x) = P(\omega_i|x) = \frac{p(x|\omega_i)P(\omega_i)}{\sum_{j=1}^c p(x|\omega_j)P(\omega_j)}$$

$$g_i(x) = p(x|\omega_i)P(\omega_i)$$

$$g_i(x) = \ln p(x|\omega_i) + \ln P(\omega_i)$$

(这里  $\ln$  是自然对数函数)

- 分类器网络的作用是将特征空间划分为  $c$  个区域 (每个类对应一个区域). 称这些区域为决策区域 (*decision regions*), 区域边界称为决策边界 (*decision boundaries*)。



# 判别公式 : Discriminant

- 令  $g_i(x) = -R(\alpha_i | x)$ , 对应与最小错误率

(此时, 最大判别对应于最小风险!)

- 令  $g_i(x) = P(\omega_i | x)$

(此时, 最大判别对应于最大后验概率!)

$$g_i(x) \equiv P(x | \omega_i) P(\omega_i)$$

$$g_i(x) = \ln P(x | \omega_i) + \ln P(\omega_i)$$



# 判别公式

- 将特征空间划分为  $c$  个决策区域

若  $g_i(x) > g_j(x) \quad \forall j \neq i$  则  $x$  在区域  $R_i$  中

( $R_i$  表示将  $x$  指定为  $\omega_i$  类)

两类的情况

此时的分类器成为二分器 (**dichotomizer**)，有两个判决函数  $g_1$  及  $g_2$

令  $g(x) \equiv g_1(x) - g_2(x)$

若  $g(x) > 0$ ，决策为  $\omega_1$ ；否则，决策为  $\omega_2$




# 决策面: Decision Surfaces

$g(x)$ 的计算

$$\begin{aligned} g(x) &= P(\omega_1 | x) - P(\omega_2 | x) \\ &= \ln \frac{P(x | \omega_1)}{P(x | \omega_2)} + \ln \frac{P(\omega_1)}{P(\omega_2)} \end{aligned}$$





- 在图中所示的2维两类分类器中，概率密度是Gaussian型的，决策边界由两条双曲线构成。这时，决策区域  $R_2$  不是单联通的，图中标记的椭圆是密度为峰值分布的  $1/e$  倍时的地方。





# 正态密度 (The Normal Density)

回顾Bayes规则，一个决策函数需要计算两个概率密度：

$$g_i(x) = p(x|\omega_i)P(\omega_i)$$

如何建立条件概率密度函数模型？

大多数时候将其假设为一个多元正态密度(**Multivariate normal density**)。  
单变量正态函数为：

$$p(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2}$$

$$\mu \equiv E[x] = \int_{-\infty}^{\infty} xp(x)dx$$


这里：

$\mu = x$ 的均值

$$\sigma \equiv E[(x-\mu)^2] = \int_{-\infty}^{\infty} (x-\mu)^2 p(x)dx$$




$\sigma^2 = x$ 的方差





- 如图所示单变量正态分布中，95%的面积处在 $|x - \mu| \leq 2\sigma$ 范围之内。分布的峰值为 $p(\mu) = 1/\sqrt{2\pi\sigma}$ .











- 若两个分布的协方差矩阵相等且均为数量矩阵, 则它们在 $d$ 维空间的分布是球形, 而边界是 $d-1$ 维的广义超平面, 并且垂直于两个分布的均值之间的连线, 位于该连线的中间位置。
- 在上图1、2、3维的例子中, 画出的是在 $P(\omega_1) = P(\omega_2)$ 条件下的 $p(\mathbf{x}|\omega_i)$ 及分类边界, 在3维情况下, 网格面将 $R_1$ 和 $R_2$ 划分开来。



当先验概率变化时，决策边界发生平移；

在先验概率差异足够大时，在1、2、3维高斯球分布的分类边界将不位于分布的均值之间。

From: Richard O. Duda,  
Peter E. Hart, and David G.  
Stork, Pattern Classification.  
Copyright c\_ 2001 by John  
Wiley & Sons, Inc.





# 信号检测 ( Signal Detection ) 理论

假设，我们将从一个信号中检测出一个单脉冲。并且假设信号受到了随机噪声的干扰。

当脉冲出现时，观察到的测量值服从均值为  $\mu_2$  的正态分布

当信号不出现时，观察到的测量值服从均值为  $\mu_1$  的正态分布


假设上述正态分布具有相同的方差.

我们能否对判别能力进行度量？

该度量是否独立于判别阈值  $x^*$  ？

判别能力: 
$$d' = \frac{|\mu_2 - \mu_1|}{\sigma}$$





- 在没有外部脉冲出现的任何瞬时时刻, 内部信号的概率密度是正态的, 即,  $p(x|\omega_1) \sim N(\mu_1, \sigma_1)$ ; 而当外部脉冲出现时, 该密度为  $p(x|\omega_2) \sim N(\mu_2, \sigma_2)$ .
- 决策阈值  $x^*$  决定了检测 (a hit) 概率(大于 $x^*$ 的曲线 $\omega_2$ 下的粉色面积) 以及虚警 (a false alarm) 概率 (小于 $x^*$ 的曲线 $\omega_1$ 下的黑色面积).



# 信号检测理论

在  $\mu_1$  ,  $\mu_2$  , 或  $x^*$  未知时, 如何确定概率  $P$ ?


由数据可算出:

1.  $P(x > x^* | x \in \omega_2)$  检测概率 (a hit) .
  2.  $P(x > x^* | x \in \omega_1)$  虚警概率 (a false alarm) .
  3.  $P(x < x^* | x \in \omega_2)$  漏检概率 (a miss) .
  4.  $P(x < x^* | x \in \omega_1)$  正确拒识概率 (a correct rejection) .
- 做出检测率 (hit) 和虚警率 (false alarm) 的比率曲线, 称该曲线为接收机工作特性曲线 (ROC, receiver operating characteristic)

利用ROC, 可以有效区分判别能力 (discriminability) 和偏差 (bias) .







- 在ROC曲线中, 横坐标是虚警率,  $P(x > x^* | x \in \omega_1)$ , 而纵坐标是检测率,  $P(x > x^* | x \in \omega_2)$ .
- 通过测量检测率和虚警率的比率, (这里对应于上页中的 $x^*$ , 图中的红点), 可以推导出  $d = 3$ .

