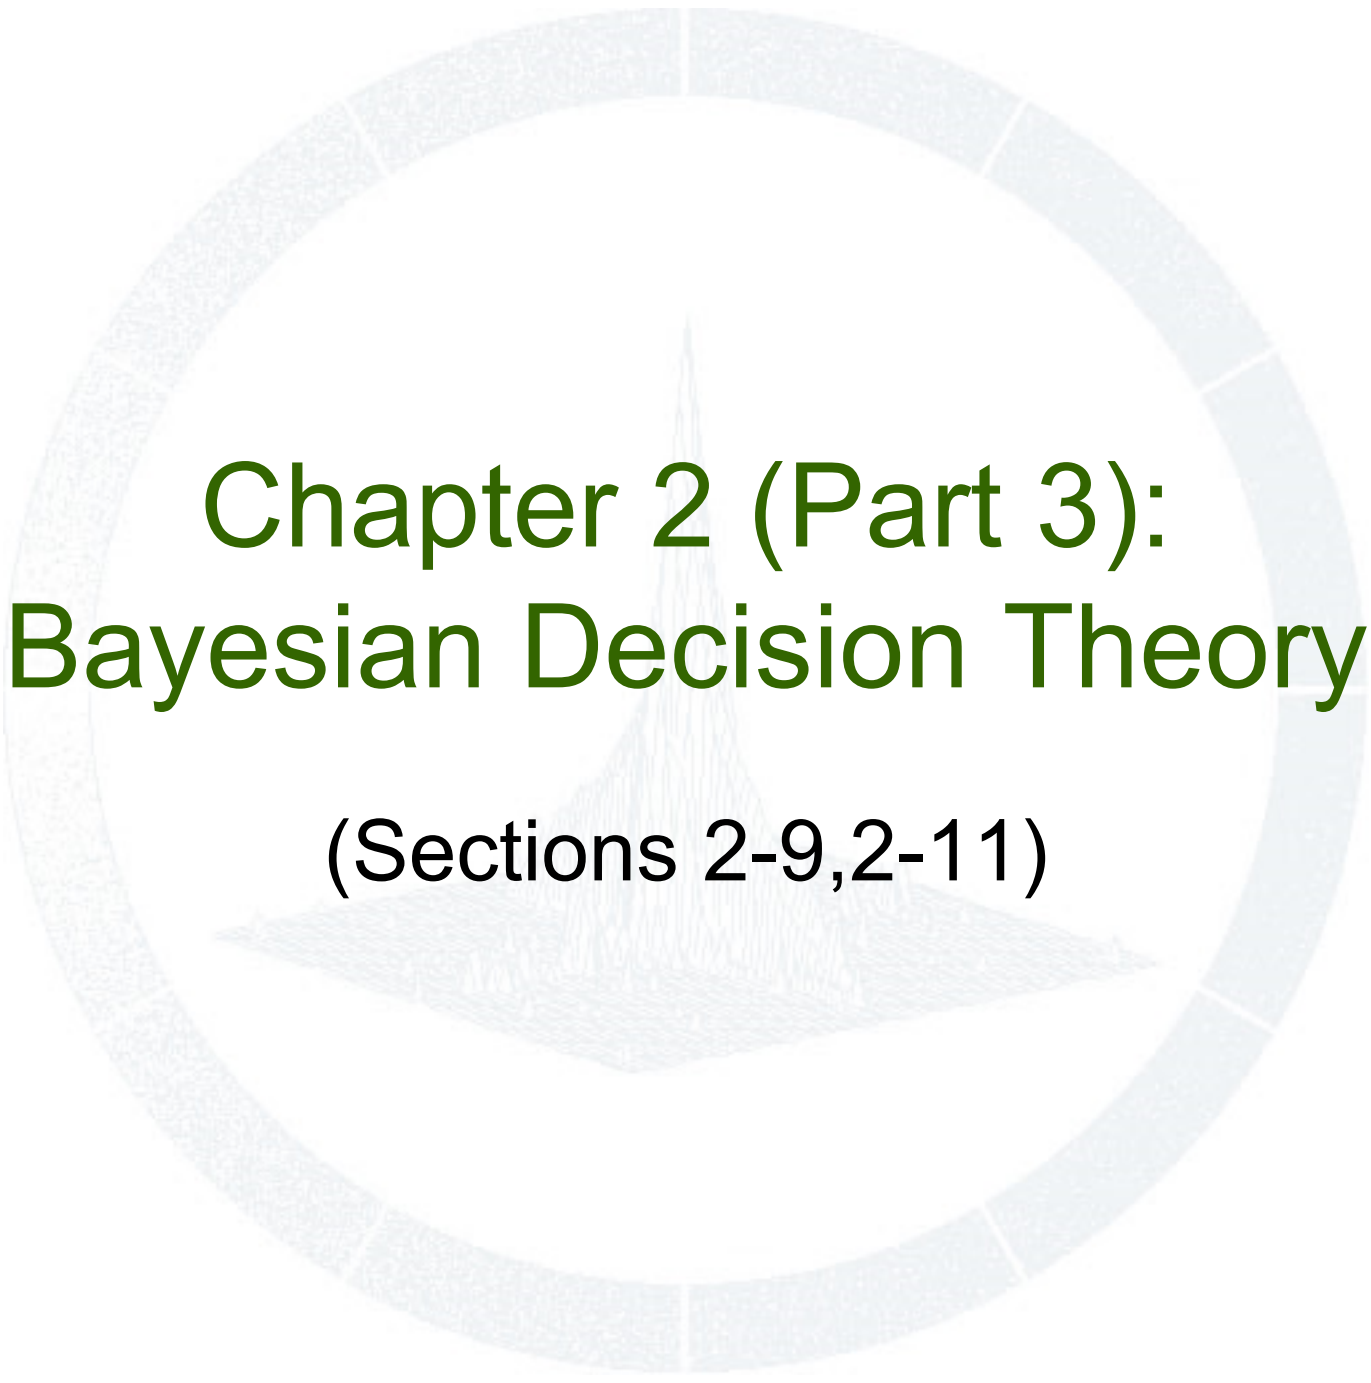




# 模式识别的理论与方法

## Pattern Recognition

裴继红



# Chapter 2 (Part 3): Bayesian Decision Theory

(Sections 2-9,2-11)

# 本讲内容

## 1. 离散特征的贝叶斯决策理论

## 2. 贝叶斯置信网



# 离散特征

- 在某些情况下，特征矢量不是在一个连续的  $d$  维实数空间中取值，其取值可以被理解为  $m$  个离散值  $v_1, v_2, \dots, v_m$  中的一个。
- 特征矢量  $x$  的每个分量的取值为离散值时，称为**离散特征**
  - 例如：颜色、纹理、类型等
- 在离散特征的条件下，**概率密度**代之以**概率分布**，概率也由积分形式变为求和形式：

$$\int p(x|\omega_j)dx \longrightarrow \sum_x p(x|\omega_j)$$

在离散特征下，在前面连续情况中得出的**贝叶斯规则**和**条件风险**的基本结论不变。



# 离散特征的贝叶斯决策理论

- 下面考虑特征矢量的分量相互独立，分量均取值为二值的两类问题的分类。即
  - 特征矢量为  $x = [x_1, x_2, \dots, x_d]^t$ ，这里  $x_i$  取值为 0 或 1，其概率分布为：

$$p_i = P(x_i = 1 / \omega_1)$$

$$q_i = P(x_i = 1 / \omega_2)$$



# 分量为二值离散的特征

只考虑两类的情况:  $\omega_1$  和  $\omega_2$ .

并且其特征取值为二值:

$x = (x_1, x_2, \dots, x_d)^T$  对每个  $x_i$  取值为 1 或 0.

对每一个特征分量, 定义两个概率:

$$p_i = P(x_i = 1 | \omega_1) \quad q_i = P(x_i = 1 | \omega_2)$$

在贝叶斯公式中, 后验概率的计算通常非常复杂:

$$P(\omega_j | x) = \frac{P(x | \omega_j) P(\omega_j)}{P(x)}$$



## 分量独立的二值特征

- 假设二值特征分量是相互独立的，则概率就比较容易求得。  
在这种情况下，条件概率可以定义为下面简单的积形式：

$$P(x|\omega_1) = \prod_{i=1}^d p_i^{x_i} (1-p_i)^{1-x_i} \quad P(x|\omega_2) = \prod_{i=1}^d q_i^{x_i} (1-q_i)^{1-x_i}$$

其中  $x_i \in \{1, 0\}$

而似然率为：

$$\frac{P(x|\omega_1)}{P(x|\omega_2)} = \prod_{i=1}^d \left( \frac{p_i}{q_i} \right)^{x_i} \left( \frac{1-p_i}{1-q_i} \right)^{1-x_i}$$



# 分量独立的二值特征的 Bayes 决策

回顾前面的贝叶斯规则。若下式成立时，选择  $\omega_1$

$$\frac{P(x|\omega_1)}{P(x|\omega_2)} > \frac{P(\omega_2)}{P(\omega_1)} \quad \text{或} \quad \ln \left[ \frac{P(x|\omega_1)}{P(x|\omega_2)} \right] - \ln \left[ \frac{P(\omega_2)}{P(\omega_1)} \right] > 0$$

此时判别函数为:

$$g(x) = \sum_{i=1}^d \left[ x_i \ln \frac{p_i}{q_i} + (1 - x_i) \ln \left( \frac{1 - p_i}{1 - q_i} \right) \right] + \ln \frac{P(\omega_1)}{P(\omega_2)}$$

也可以表示为

$$g(x) = \sum_{i=1}^d \omega_i x_i + \omega_0 \quad (\text{特征分量的线性组合})$$

$$\omega_i = \ln \frac{p_i(1 - q_i)}{q_i(1 - p_i)} \quad \omega_0 = \sum_{i=1}^d \ln \left( \frac{1 - p_i}{1 - q_i} \right) + \ln \frac{P(\omega_1)}{P(\omega_2)}$$





# 本讲内容

1. 离散特征的贝叶斯决策理论

**2. 贝叶斯置信网**



# 贝叶斯置信网：变量统计独立

- 两个随机变量统计独立的含义如下：
  - 考虑一个多维分布  $p(x)$ ，若对其两个特征，有

$$p(x_i, x_j) = p(x_i) p(x_j)$$

则称这两个特征是统计独立的。

- 若已知了那一些特征是独立的，那一些不是独立的，则其联合概率密度的计算就比较简单



# 贝叶斯置信网

- 贝叶斯置信网（Bayesian Belief Network, **BBN**）是描述变量集合的联合概率分布的一种方法。
  - BBN也称为因果网（Casual Network, **CN**）
  - 或信任网（Belief Net, **BN**）。

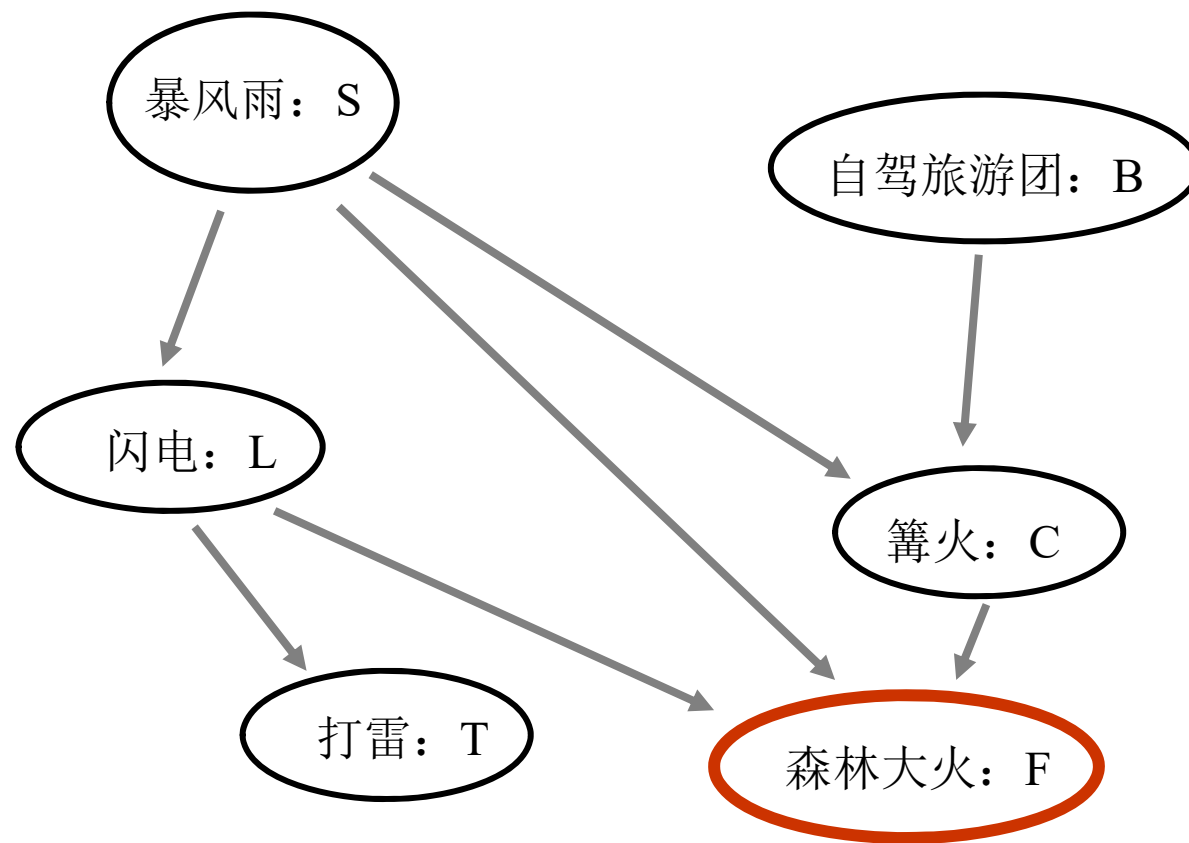
令  $x = x_1, x_2, \dots, x_n$  是一个特征变量的集合

则利用贝叶斯置信网 **BBN** 可以计算  $x = x_1, x_2, \dots, x_n$  中的任意分量组合的联合概率




# 贝叶斯置信网：一个例子

- 二值变量和它们的关系集合




# 贝叶斯置信网：条件概率

	S,B	S, $\sim$ B	$\sim$ S,B	$\sim$ S, $\sim$ B
C	0.4	0.1	0.8	0.2
$\sim$ C	0.6	0.9	0.2	0.8



# 条件概率：一个例子

	S,B	S,~B	~S,B	~S,~B
C	0.4	0.1	0.8	0.2
~C	0.6	0.9	0.2	0.8



# 贝叶斯置信网：条件独立

- 若  $x_1$  的概率独立于给定  $x_3$  时  $x_2$  的概率，则称  $x_1$  条件独立于给定  $x_3$  时的  $x_2$ :

$$P(x_1 | x_2, x_3) = P(x_1 | x_3)$$

- 对于随机变量集合也具有相同的结论。即


$x_1, x_2, x_3$  条件独立于给定  $z_1, z_2, z_3$  时的  $y_1, y_2, y_3$  是指:

$$P(x_1, x_2, x_3 | y_1, y_2, y_3, z_1, z_2, z_3) = P(x_1, x_2, x_3 | z_1, z_2, z_3)$$



# 贝叶斯置信网：描述


- BBN 明确而直观地描述了条件独立假设下，随机变量集合的联合概率分布。具体要用到：
  - 有向无环图（directed acyclic graph）
  - 局部条件概率






# 贝叶斯置信网：描述

- 每一个变量与其前辈导出的其他子节点构成**非子代**时，则**子节点间相互独立**。
- $x_1$  是  $x_2$  的一个子孙节点：是指在有向图中存在一条从  $x_2$  到  $x_1$  的有向路径。例如：
  - “篝火C”的前辈节点：“暴风雨S”，“自驾旅游团B”。(C是这两个变量S和B的子孙节点).
  - “篝火C”独立于由它的前辈节点给出的子孙节点“闪电L”



- 如图为某置信网的一部分。包含一个节点 **X**, 变量取值为  $(x_1, x_2, \dots)$ , 其父节点 (**A** 和 **B**), 子节点 (**C** 和 **D**)



# 联合概率分布

- 给定一个贝叶斯置信网 **BBN**，用下面的公式可以简单地计算出一个变量集合的联合概率密度：

$$P(x_1, x_2, \dots, x_n) = \prod_i P(x_i | \text{parents}(x_i))$$

- 这里 **parents** 是  $x_i$  的直接前辈节点。

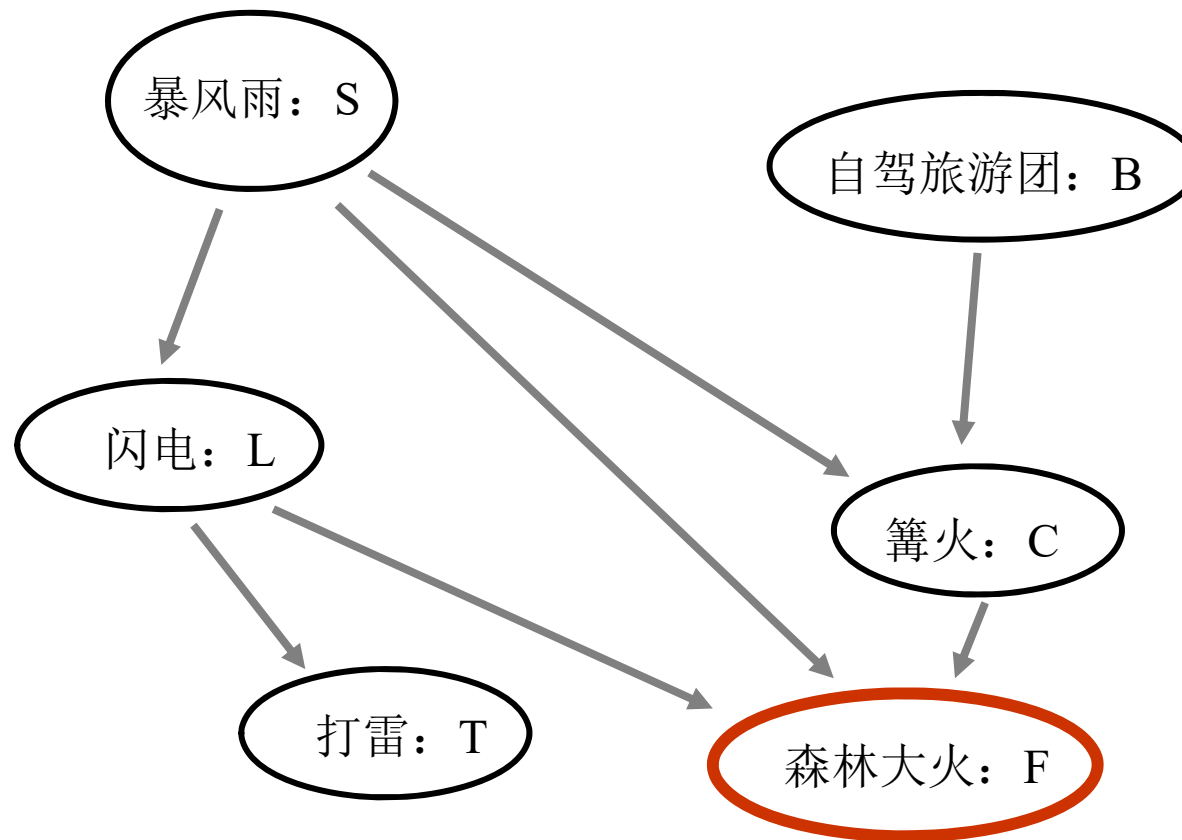
例如：

$$P(C, S, B, L, T, F)?$$

$$= P(S)P(B)P(C|S,B) P(L|S)P(T|L)P(F|L,S,C).$$



## 联合分布：一个例子



$$P(C, S, B, L, T, F) = P(S)P(B)P(C|S,B)P(L|S)P(T|L)P(F|L,S,C).$$



# 置信网的学习

BBN 可以采用不同的方式学习。下面是两个基本的方法:

1) 假设已知网络结构:

- 可以从已知数据的每一个变量估计条件概率

2) 假设知道部分的网络结构, 但是丢失了一些变量:

- 类似于在神经网络中对隐单元节点的学习。
- 可以用梯度下降的方法训练 **BBN**.


- 假设什么都是未知的

- 我们可以通过可能的网络空间中进行观察、学习网络结构和条件概率。



# BBN与分类的关系

- 假设其中的一个变量是目标变量，可以计算给定其他变量下目标变量的概率。




$$P(x_1, x_2, \dots, x_n, \omega_j) = P(\omega_j) P(x_1 | \omega_j) P(x_2 | \omega_j) \cdots P(x_n | \omega_j)$$



# 一般情况

- 在一般情况下，可以使用 **BBN** 详细说明变量之间的独立性假设.



$$P(x_1, x_2, \dots, x_n, \omega_j) = P(\omega_j) P(x_1 | \omega_j) P(x_2 | \omega_j) P(x_3 | x_1, x_2, \omega_j) P(x_4 | \omega_j)$$



# 本章要点

- ① 贝叶斯公式和贝叶斯决策论
- ② 损失函数 (e.g., zero-one loss)
- ③ 判别函数
- ④ **ROC 曲线**
- ⑤ 独立二值特征下的判别函数
- ⑥ 条件独立
- ⑦ 贝叶斯置信网 **BBN**

