模式识别的理论与方法 Pattern Recognition

裴继红

Chapter 3 (Part 2): Maximum Likelihood and Bayesian Parameter Estimation

(Sections 3.3-3.5)

本讲内容: 贝叶斯参数估计

- 贝叶斯估计 (BE)
- 贝叶斯估计: 高斯分布的情况
- 贝叶斯估计: 一般情况下的估计问题



回顾: 贝叶斯决策

后验概率 $P(\omega_i \mid x)$ 的计算是贝叶斯分类的核心

• 目标:计算 $P(\omega_i \mid x, D)$ 给定训练样本集合 D,将贝叶斯公式重新写为

$$P(\omega_i \mid x, D) = \frac{P(x \mid \omega_i, D)P(\omega_i \mid D)}{\sum_{j=1}^{c} P(x \mid \omega_j, D)P(\omega_j \mid D)}$$



类条件密度

- ① 由贝叶斯公式,计算 $P(\omega_j \mid x, D)$ 转化为计算 $P(x \mid \omega_j, D)$ 和 $P(\omega_i \mid D)$
- ② 对于有监督学习,事先知道每个样本的类属信息,因此 先验概率容易得到

假设样本类数 c,每一类的样本相互独立,则

 $P(\omega_{i} \mid D) \rightarrow P(\omega_{i} \mid D_{1}, D_{2}, \dots D_{i}, \dots D_{c}) \rightarrow P(\omega_{i} \mid D_{i}) \rightarrow P(\omega_{i})$

此时,后验概率 $P(\omega_i \mid x, D) \rightarrow P(\omega_i \mid x, D_i)$

在不引起混淆的情况下,为了书写方便常用 D 替代 D_i



类条件密度

贝叶斯公式的证明:

$$P(x, \omega_i | D_i) = P(x | D_i, \omega_i) P(\omega_i | D_i)$$

$$P(x | D) = \sum_j P(x, \omega_j | D_j)$$

$$P(\omega_i) = P(\omega_i | D) \text{ (训练样本提供了这些信息!)}$$

这样:

件:
$$P(\omega_i \mid x, D) = \frac{P(x \mid \omega_i, D_i) P(\omega_i \mid D)}{P(x \mid D)} = \frac{P(x \mid \omega_i, D_i) P(\omega_i)}{\sum_{j=1}^{c} P(x \mid \omega_j, D_j) P(\omega_j)}$$

或记为:
$$P(\omega_i \mid x, D) = \frac{P(x \mid \omega_i, D)P(\omega_i)}{\sum_{j=1}^{c} P(x \mid \omega_j, D)P(\omega_j)}$$



贝叶斯参数学习

- 在MLE中,假设参数θ未知,但它是确定的量
- · 在BE中,参数θ是一个随机变量
 - 1. 条件概率 $P(x|D) = P(x|\omega_i, D_i)$ 的计算是贝叶斯学习的目的
 - 2. 核心问题: 给定样本集合D, 计算 P(θ| D)

$$p(x|D) = \int p(x|\theta) p(\theta|D) d\theta$$

离散情况

$$p(x|D) = \sum_{j} p(x|\theta_{j}) p(\theta_{j}|D)$$



举例1: 高斯分布,均值μ未知

目标: 使用后验概率密度 $P(\theta \mid D)$ 估计参数 θ

首先,考虑一元变量情况: P(μ | D) 即这里, 只有均值 μ 是未知的参数

$$P(x \mid \mu) \sim N(\mu, \sigma^2)$$
 $P(\mu) \sim N(\mu_0, \sigma_0^2)$

 $(\sigma \setminus \mu_0$ 和 σ_0 是已知的!)



举例1: 高斯分布,均值μ未知

$$P(\mu \mid D) = \frac{P(D \mid \mu)P(\mu)}{\int P(D \mid \mu)P(\mu)d\mu}$$

$$= \alpha \prod_{k=1}^{n} P(x_k \mid \mu)P(\mu)$$
(1)

复制密度

$$P(\mu \mid \mathbf{D}) \sim N(\mu_n, \sigma_n^2) \tag{2}$$

由式(1)和(2),可以推导出:

$$\mu_n = \left(\frac{n\sigma_0^2}{n\sigma_0^2 + \sigma^2}\right)\hat{\mu}_n + \frac{\sigma^2}{n\sigma_0^2 + \sigma^2}\mu_0 \qquad \sigma_n^2 = \frac{\sigma_0^2\sigma^2}{n\sigma_0^2 + \sigma^2}$$

$$\hat{\mu}_n = \frac{1}{n} \sum_{k=1}^n x_k$$



举例1: 高斯分布,均值μ未知

• 单变量高斯分布 P(x | D)

计算出 P(μ | D)

然后,测试样本的条件概率密度 $P(x \mid D)$ 可以被计算出来!

$$P(x \mid D) = \int P(x \mid \mu) P(\mu \mid D) d\mu$$

在高斯分布情况下:

$$P(x \mid D) \sim N(\mu_n, \sigma^2 + \sigma_n^2)$$


得到类条件概率密度 $P(x \mid D_i, \omega_i)$

• 因此: $P(x | D_j, \omega_j)$ 与 $P(\omega_j)$ 一起,利用贝叶斯公式,可得到贝叶斯分类规则如下:

$$\max_{\omega_{j}} \left[P(\omega_{j} \mid x, D) \right] = \max_{\omega_{j}} \left[P(x \mid \omega_{j}, D_{j}) P(\omega_{j}) \right]$$



Figure 3.2



• 在1维和2维空间中正态分布时,均值参数的贝叶斯学习。 图中后验分布的估计图上标注的数字是在估计中使用的样本数量



贝叶斯参数估计:一般情况

 $P(x \mid D)$ 的计算可以应用于任何的分布密度未知、但可以被参数化的情况。

▶ 基本假设如下:

- 1. 假设 $P(x \mid \theta)$ 的形式是已知的, 但参数 θ 的准确值未知;
- 2. 对 θ 的先验知识假定已经包含在一个已知的先验密度 $P(\theta)$ 之中。
- 3. 关于 θ 的其余的知识包含在:具有 n 个随机样本 $x_1, x_2, ..., x_n$ 的数据集合 D 中,该样本集合是由 P(x) 经过独立抽样得到。



贝叶斯参数估计:核心问题

因此,贝叶斯参数估计的最本质的核心问题为:

- ① 计算出后验密度 P(θ | D)
- ② 然后导出 条件概率P(x | D)

$$p(x|D) = \int p(x|\theta) p(\theta|D) d\theta$$

应用贝叶斯公式:

$$P(\theta \mid D) = \frac{P(D \mid \theta)P(\theta)}{\int P(D \mid \theta)P(\theta)d\theta}$$

由独立性假设有:

$$P(D \mid \theta) = \prod_{k=1}^{n} P(x_k \mid \theta)$$



具体算法1: 增量学习参数估计方法

• 假设集合 D^n 中包含同一类的 n 个样本,且这些样本是独立同分布抽样得到的,记为 $D^n = \{x_1, x_2, ..., x_n\}$, D^{n-1} 为其前n-1个样本组成的集合。则

$$P(D^{n} | \theta) = \prod_{k=1}^{n} P(x_{k} | \theta) = P(x_{n} | \theta) \prod_{k=1}^{n-1} P(x_{k} | \theta) = P(x_{n} | \theta) P(D^{n-1} | \theta)$$

$$P(\theta \mid \mathbf{D}^{n}) = \frac{P(D^{n} \mid \theta)P(\theta)}{\int P(D^{n} \mid \theta)P(\theta)d\theta} = \frac{P(\mathbf{x}_{n} \mid \theta)P(\theta \mid D^{n-1})}{\int P(\mathbf{x}_{n} \mid \theta)P(\theta \mid D^{n-1})d\theta}$$

$$P(\theta \mid \mathbf{D}^0) = P(\theta)$$



其他算法

- EM
- Gibbs

•

