# 模式识别的理论与方法 Pattern Recognition

裴继红

# Chapter 3 (Part 3): Maximum Likelihood and Bayesian Parameter Estimation

(Sections 3.6-3.8)

# 本讲内容: FDA

- Fisher判别分析 FDA
- Fisher多重判别分析 MDA



# 特征空间降维的方法

- □ 可以采用特征线性组合的方法减少特征空间中特征的维数。 将高维数据投影到较低维空间上。主成分分析和判别分析 是两类有效的线性组合变换方法
- 1. 主成分分析 ( Principal Component Analysis, PCA )
  - ▶ 基本思路: 寻找在最小均方误差意义下最能代表数据特性的 投影方向,用这些方向矢量表示数据。
- 2. Fisher判别分析(Fisher Discriminant Analysis ,FDA)
  - ▶ 基本思路:在最小均方误差意义一下,寻找最能够分开各个 类别数据的最佳方向。






#### Fisher 线性判别分析 (Fisher Linear Discriminant Analysis, FDA)

➤ PCA 寻找的是用来有效表示同一类样本共同特点的主轴方向,也即PCA方法对于表示同一类数据样本的共同特征是非常有效的。但PCA方法不适合用于区分不同的样本类。

PCA 2nd Dimention


5
-10
-5
-10
-15
-20
-20
-25
-10
-8
-6
-4
-2
0
2
4
6


• Fisher线性判别分析(FDA)是 用于寻找对不同样本类样本进行 区分的最有效方向。






# FDA的基本原理





▶ 同一组样本点在不同方向 投影后可分性不同





## FDA的基本原理:向直线投影

▶ 可分性分析的目标:考虑将d维空间中的点投影到一条直线上。通过适当地选择直线的方向,有可能找到能够最大限度地区分各类样本数据点的投影方向。

假设:一组由 $n \land d$  维样本组成的数据集合 $\{\mathbf{x}_1, \mathbf{x}_2, ..., \mathbf{x}_n\}$ ,它们分属于两个不同的类 $\omega_1$ 和 $\omega_2$ ,其中 $\omega_1$ 类的样本子集为 $\mathbf{D}_1$ ,包含 $n_1$ 个样本点; $\omega_2$ 类的样本子集为 $\mathbf{D}_2$ ,包含 $n_2$ 个样本点。


将每一个样本点投影到方向为w的直线上,其中||w||=1,


$$y = \mathbf{w}^t \mathbf{x}$$

则:得到n个投影标量 $y_1, y_2, ..., y_n$ ,对应于 $\omega_1$ 和 $\omega_2$ ,分别属于集合 $Y_1$ 和 $Y_2$ 



# **FDA**







#### FDA的基本原理: 向直线投影

► 假设m<sub>i</sub>是ω<sub>i</sub>类的样本均值,即

$$\mathbf{m}_{i} = \frac{1}{n_{i}} \sum_{x \in D_{i}} \mathbf{x}$$

则投影后的样本均值为:

$$\tilde{\mathbf{m}}_{i} = \frac{1}{n_{i}} \sum_{y \in Y_{i}} y = \frac{1}{n_{i}} \sum_{x \in D_{i}} \mathbf{w}^{t} \mathbf{x} = \mathbf{w}^{t} \mathbf{m}_{i}$$

投影后的样本均值之差为:

$$\left|\tilde{\mathbf{m}}_{1}-\tilde{\mathbf{m}}_{2}\right|=\left|\mathbf{w}^{t}\left(\mathbf{m}_{1}-\mathbf{m}_{2}\right)\right|$$



#### 类内散布矩阵、Fisher线性可分性准则

• 投影后, ω, 类的类内散布为

$$\tilde{s}_i^2 = \sum_{y \in Y_i} (y - \tilde{\mathbf{m}}_i)^2$$

在投影 y = w t x 下, Fisher线性可分性准则函数为

$$J(\mathbf{w}) = \frac{\left|\tilde{\mathbf{m}}_{1} - \tilde{\mathbf{m}}_{2}\right|^{2}}{\tilde{s}_{1}^{2} + \tilde{s}_{2}^{2}}$$

 $\tilde{s}_1^2 + \tilde{s}_2^2$  称为投影样本的总类内散布



#### 投影前的类内散布矩阵、类间散布矩阵

• 投影前, 类内散布矩阵为

$$\mathbf{S}_{i} = \sum_{\mathbf{x} \in D_{i}} (\mathbf{x} - \mathbf{m}_{i}) (\mathbf{x} - \mathbf{m}_{i})^{t}$$

总类内散布矩阵为

$$\mathbf{S}_W = \mathbf{S}_1 + \mathbf{S}_2$$

总类间散布矩阵为

$$\mathbf{S}_B = (\mathbf{m}_1 - \mathbf{m}_2)(\mathbf{m}_1 - \mathbf{m}_2)^t$$



#### 投影后的类内散布矩阵、总类内散布矩阵

• 投影后, 类内散布矩阵为

$$\tilde{\mathbf{s}}_{i}^{2} = \sum_{\mathbf{x} \in D_{i}} (\mathbf{w}^{t} \mathbf{x} - \mathbf{w}^{t} \mathbf{m}_{i})^{2} = \sum_{\mathbf{x} \in D_{i}} \mathbf{w}^{t} (\mathbf{x} - \mathbf{m}_{i}) (\mathbf{x} - \mathbf{m}_{i})^{t} \mathbf{w} = \mathbf{w}^{t} \mathbf{S}_{i} \mathbf{w}$$

总类内散布矩阵为

$$\tilde{\mathbf{s}}_1^2 + \tilde{\mathbf{s}}_2^2 = \mathbf{w}^t \mathbf{S}_W \mathbf{w}$$



#### 投影后样本均值之差的类间散布矩阵表示

• 投影样本均值之差可以表示为

$$(\tilde{\mathbf{m}}_{1} - \tilde{\mathbf{m}}_{2})^{2} = (\mathbf{w}^{t} \mathbf{m}_{1} - \mathbf{w}^{t} \mathbf{m}_{2})^{2}$$

$$= \mathbf{w}^{t} (\mathbf{m}_{1} - \mathbf{m}_{2}) (\mathbf{m}_{1} - \mathbf{m}_{2})^{t} \mathbf{w} = \mathbf{w}^{t} \mathbf{S}_{B} \mathbf{w}$$

$$(\tilde{\mathbf{m}}_{1} - \tilde{\mathbf{m}}_{2})^{2} = \mathbf{w}^{t} \mathbf{S}_{B} \mathbf{w}$$

其中 
$$\mathbf{S}_B = (\mathbf{m}_1 - \mathbf{m}_2)(\mathbf{m}_1 - \mathbf{m}_2)^t$$



#### Fisher判别准则函数——广义瑞利商

用类内总散布矩阵和类间总散布矩阵表示的Fisher判别 准则函数为

$$J\left(\mathbf{w}\right) = \frac{\mathbf{w}^{t} \mathbf{S}_{B} \mathbf{w}}{\mathbf{w}^{t} \mathbf{S}_{W} \mathbf{w}}$$

该准则函数也称为广义瑞利商。

Fisher判别分析的目的就是要找到使得该准则函数 *J(.)* 最大化时的直线w



# FDA原理: 基于Fisher判别准则函数优化的最大类可分性投影方向W的求解

• 使 J(.) 最大化时的直线w 必须满足方程:

$$\mathbf{S}_{B}\mathbf{w} = \lambda \mathbf{S}_{W}\mathbf{w}$$

若  $S_W$  非奇异,则 w 是 $S_W^{-1}S_B$  的特征矢量,即满足


$$\mathbf{S}_{W}^{-1}\mathbf{S}_{R}\mathbf{w}=\lambda\,\mathbf{w}$$


$$\mathbf{S}_{B}\mathbf{w} = (\mathbf{m}_{1} - \mathbf{m}_{2})(\mathbf{m}_{1} - \mathbf{m}_{2})^{t} \mathbf{w} = (\mathbf{m}_{1} - \mathbf{m}_{2}) \left[ (\mathbf{m}_{1} - \mathbf{m}_{2})^{t} \mathbf{w} \right] = a \cdot (\mathbf{m}_{1} - \mathbf{m}_{2})$$

即  $S_B$ w 的方向与矢量  $m_1$ - $m_2$  的方向相同,而我们主要关心的是w 的方向,w 的模对问题的求解无关紧要,因此可得 使 J(.) 最大化时的w为

$$\mathbf{w} = \mathbf{S}_W^{-1} \left( \mathbf{m}_1 - \mathbf{m}_2 \right)$$









# 多重判别分析 (MDA)

- ➤ 对于c>2类的 分类问题,为推广Fisher线性判别准则,需要c-1个判别函数。
- ▶ 此时需要从d维空间向c-1维空间进行投影。







#### MDA: 类内散布矩阵

➤ 假设d≥c, 此时类内散布矩阵为

$$\mathbf{S}_W = \sum_{i=1}^c \mathbf{S}_i$$

其中: 
$$\mathbf{S}_i = \sum_{x \in D_i} (\mathbf{x} - \mathbf{m}_i) (\mathbf{x} - \mathbf{m}_i)^t$$

$$\mathbf{m}_{i} = \frac{1}{n_{i}} \sum_{x \in D_{i}} \mathbf{x}$$



#### MDA:

#### 总体均值向量、类内散布矩阵、总体散布矩阵

$$\mathbf{m} = \frac{1}{n} \sum_{\mathbf{x}} \mathbf{x} = \frac{1}{n} \sum_{i=1}^{c} n_i \mathbf{m}_i$$

$$\mathbf{S}_{B} = \sum_{i=1}^{c} n_{i} \left( \mathbf{m}_{i} - \mathbf{m} \right) \left( \mathbf{m}_{i} - \mathbf{m} \right)^{t}$$

总体散布矩阵: 
$$\mathbf{S}_T = \sum_{\mathbf{x}} (\mathbf{x} - \mathbf{m}) (\mathbf{x} - \mathbf{m})^t$$

$$= \mathbf{S}_W + \sum_{i=1}^c n_i (\mathbf{m}_i - \mathbf{m}) (\mathbf{m}_i - \mathbf{m})^t$$

$$\mathbf{S}_T = \mathbf{S}_W + \mathbf{S}_B$$



#### MDA: d维空间向c-1维空间投影

• 从d维空间向c-1维空间进行投影,通过 c-1个分类 过程进行

或写成矩阵形式  $\mathbf{y} = \mathbf{W}^t \mathbf{x}$ 

其中,W为d $\times$ (c-1)的矩阵,矩阵的每一行是d维的矢量 $w_i$ 



#### MDA:

#### 向c-1维投影后的均值向量、散布矩阵

• 从d维空间向c-1维空间进行投影后的均值向量

$$\tilde{\mathbf{m}}_i = \frac{1}{n_i} \sum_{\mathbf{y} \in Y_i} \mathbf{y}$$
 $\tilde{\mathbf{m}} = \frac{1}{n} \sum_{i=1}^c n_i \tilde{\mathbf{m}}_i$ 

散布矩阵

$$\tilde{\mathbf{S}}_{W} = \sum_{i=1}^{c} \sum_{\mathbf{y} \in Y_{i}} (\mathbf{y} - \tilde{\mathbf{m}}_{i}) (\mathbf{y} - \tilde{\mathbf{m}}_{i})^{t}$$

$$\tilde{\mathbf{S}}_{B} = \sum_{i=1}^{c} n_{i} \left( \tilde{\mathbf{m}}_{i} - \tilde{\mathbf{m}} \right) \left( \tilde{\mathbf{m}}_{i} - \tilde{\mathbf{m}} \right)^{t}$$



#### MDA: 投影前、后散布矩阵之间的关系

• 易证明投影前后散布矩阵之间的关系

$$\tilde{\mathbf{S}}_W = \mathbf{W}^t \mathbf{S}_W \mathbf{W}$$

$$\tilde{\mathbf{S}}_B = \mathbf{W}^t \mathbf{S}_B \mathbf{W}$$



#### MDA: 准则函数

• MDA准则函数

$$J\left(\mathbf{W}\right) = \frac{\left|\tilde{\mathbf{S}}_{B}\right|}{\left|\tilde{\mathbf{S}}_{W}\right|} = \frac{\left|\mathbf{W}^{t}\mathbf{S}_{B}\mathbf{W}\right|}{\left|\mathbf{W}^{t}\mathbf{S}_{W}\mathbf{W}\right|}$$

最优解的特征矢量 w<sub>i</sub>满足的条件

$$\mathbf{S}_{B}\mathbf{w}_{i}=\lambda_{i}\mathbf{S}_{W}\mathbf{w}_{i}$$

因为, $S_B$ 的秩  $\leq c-1$ ,

所以,上述公式中非零特征值的个数最多只有 c-1 个,

而最优解的特征矢量wi满足这些非零特征值对应的特征向量



# MDA: 求解最优解的特征矢量 $\mathbf{w}_i$

$$\mathbf{S}_{B}\mathbf{w}_{i}=\lambda_{i}\mathbf{S}_{W}\mathbf{w}_{i}$$

① 若 $S_w$  可逆,最优解的特征矢量  $W_i$  满足

$$\mathbf{S}_{W}^{-1}\mathbf{S}_{B}\mathbf{w}_{i}=\lambda_{i}\mathbf{w}_{i}$$

则  $S^{-1}_{w}$   $S_{B}$ 的c-1个非零特征值对应的特征向量 $w_{i}$ 就是最优解的特征矢量

② 若类内散布矩阵各向同性,此时c-1个特征矢量  $w_i$  可以由 c-1个向量:


$$\mathbf{m}_{i}$$
- $\mathbf{m}$ ,  $i = 1, 2, ... c - 1$ 

通过Gram-Schmidt正交化方法得到。



## MDA投影判别示意: Figure 3-6

• 三个三维分布的样本被分别投影到用法向量W<sub>1</sub>、W<sub>2</sub>所表示的二维平面上,在不同的投影面上,样本投影结果有不同的分离度





# 几点说明

- 若实际可以得到的训练样本非常少,就需要向更低维的空间作投影;而若样本数量较多,则适合向较高维的空间进行投影。
- 在两类情况下,多重判别分析提供了一种合理的降维方法。
- 除了 PCA 和 MDA 可以进行降维,还存在一些其他的线性和非线性降维方法,如局部线性嵌入方法等。

