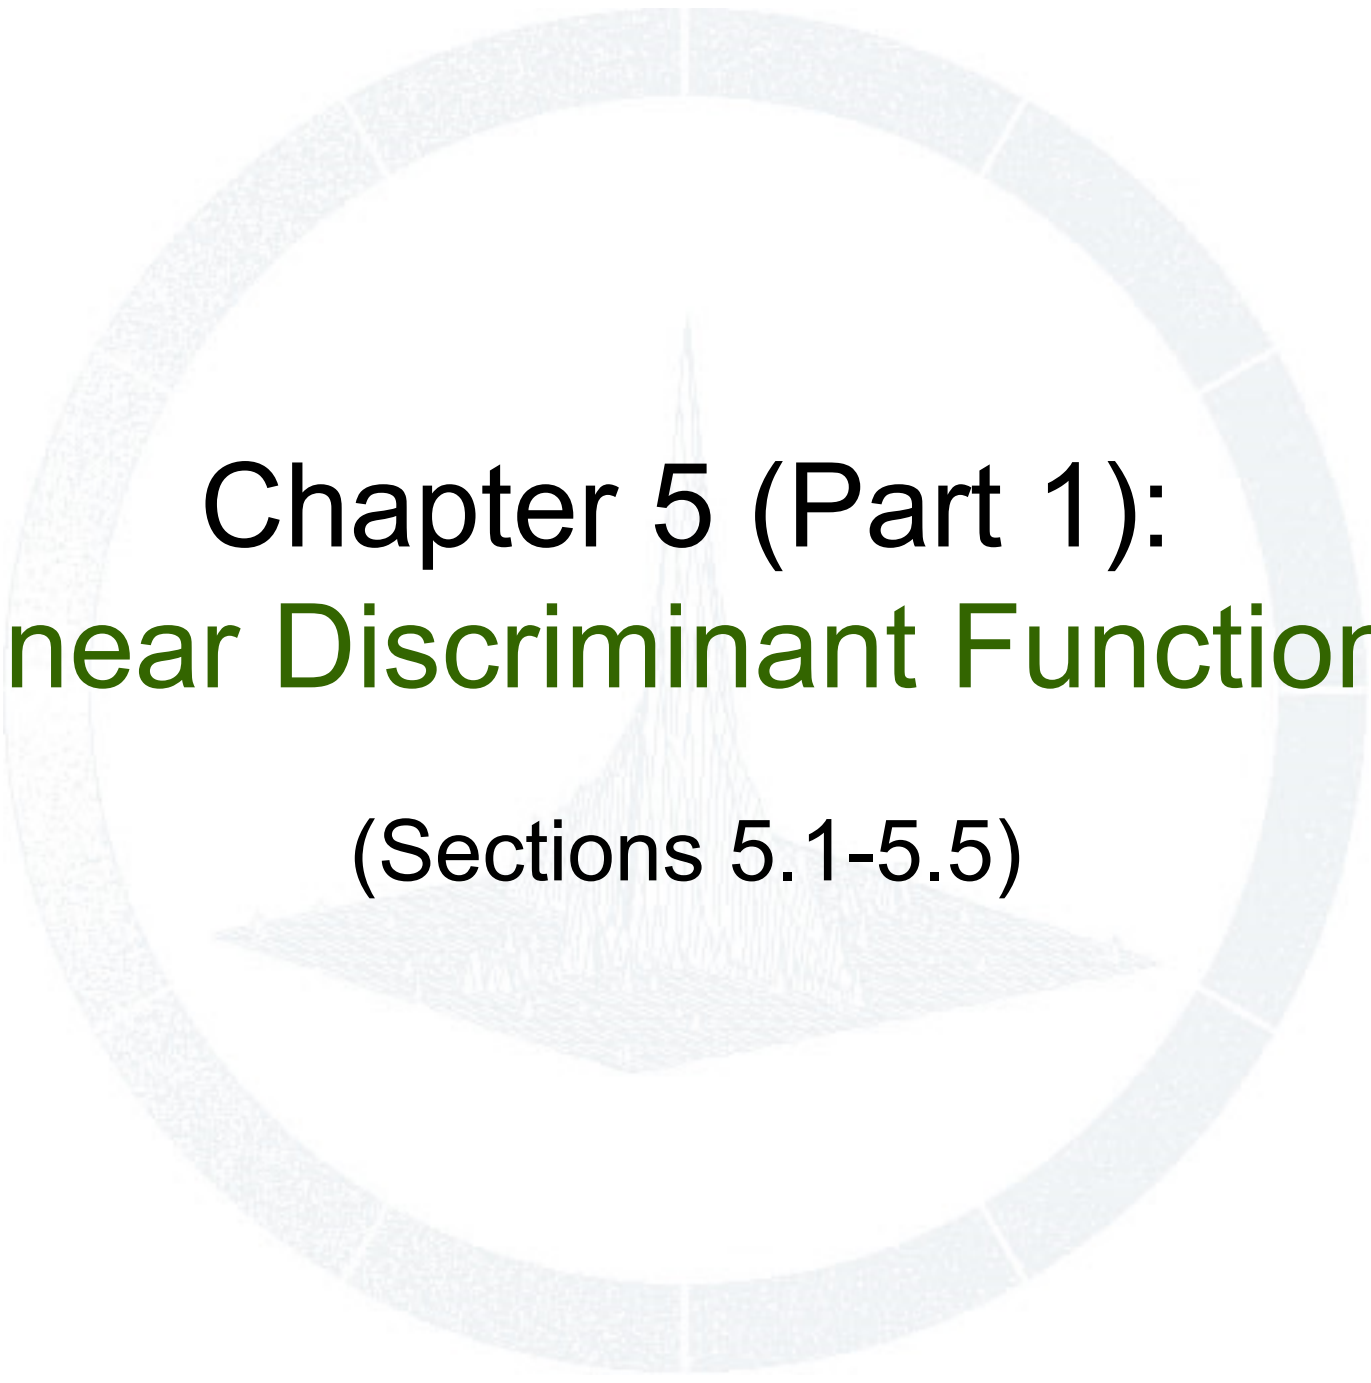




模式识别的理论与方法

Pattern Recognition

裴继红



Chapter 5 (Part 1): Linear Discriminant Functions

(Sections 5.1-5.5)

引言

- 在第 3 章中，假设关于模式类的内在的概率密度是已知、或已经给出的。
 - 训练样本是用来估计这些概率密度的参数的（如ML方法，MAP方法）
- 在本章中，我们假设仅仅知道判别函数的适当的形式，依此来作为分类器训练的先验知识。
 - 基本思想与非参数估计很类似。
 - 得到的分类器——**线性分类器**也许不是最优的，但使用起来却非常简单。



本讲内容

- 线性判别函数和判决面
- 多类情况下的线性判别函数
- 线性分类机
- 广义线性判别函数



线性方程、线性函数回顾

1. 线性方程的常用形式

- 斜截式、法线式、一般式、.....

2. 线性方程的几何意义

- 超平面
- 原点到超平面的距离

3. 线性函数的几何意义

- 点与直线（超平面）的关系
- 点到直线（超平面）的距离



线性判别函数

➤ 定义

线性判别函数是将特征矢量 \mathbf{x} 的各个分量经线性组合而成的函数。

$$g(\mathbf{x}) = \mathbf{w}^t \mathbf{x} + w_0 \quad (1)$$

这里， \mathbf{w} 称为**权矢量**， w_0 称为**阈值**或**偏置**

➤ 对式（1）的**两类**分类器，判别函数使用如下的**决策规则**：

若 $g(\mathbf{x}) > 0$ ，则判别为 ω_1 ；若 $g(\mathbf{x}) < 0$ ，则判别为 ω_2


⇔ 若 $\mathbf{w}^t \mathbf{x} > -w_0$ ，则判别为 ω_1 ；否则，判别为 ω_2

特别，若 $g(\mathbf{x}) = 0 \Rightarrow \mathbf{x}$ 可以指派为任意一个类



两类情况的线性分类器模型

- ① 有 d 个输入单元的简单线性分类器，其中每一个单元对应输入矢量的一个分量值；
- ② 偏置单元的输入是常数=1.0；
- ③ 输入单元是线性的，输出的是其特征值的准确值；
- ④ 每个输入的特征值 x_i 与其对应的权值 w_i 相乘；
- ⑤ 输出单元的有效输入是所有这些积之和 $\sum w_i x_i$ 。
- ⑥ 输出单元的输出为+1 （若 $\mathbf{w}^t \mathbf{x} + w_0 > 0$ ）或-1 （ $\mathbf{w}^t \mathbf{x} + w_0 \leq 0$ ）



决策面、线性决策面

- 方程 $g(x) = 0$ 定义了一个将属于 ω_1 类的点与属于 ω_2 类的点分隔开来的决策面
- 由于 $g(x)$ 是线性函数，因此决策面 $g(x) = 0$ 是一个线性超平面


说明：线性函数 $g(x)$ 的输出值，给出了从特征矢量 x 到该超平面的距离的代数度量



模式矢量点与判决边界: Figure5.2

- 线性决策边界 H , 边界中 $g(x) = \mathbf{w}^t \mathbf{x} + w_0 = 0$, 将特征空间划分为两个半空间 R_1 (其中 $g(x) > 0$), 以及 R_2 (其中 $g(x) < 0$).

$$r = \frac{g(x)}{\|\mathbf{w}\|} \quad d(0, H) = \frac{w_0}{\|\mathbf{w}\|}$$



决策面的法向量 w

- 超平面 H 将特征空间划分为两个区域：
 - 区域 $R1$ 对应于类 ω_1
 - 区域 $R2$ 对应于类 ω_2
- 对于在决策面上的两个点 x_1 和 x_2 :

$$w^t x_1 + w_0 = w^t x_2 + w_0$$

进行简单的变换:

$$w^t (x_1 - x_2) = 0$$

w 与超平面中的任何矢量均正交。因此， w 是超平面的法向量。



代数距离度量

➤ 函数 $g(x)$ 表示了 x 距决策边界的距离有多远:

点 x 可以表示为
$$x = x_p + r \frac{w}{\|w\|}$$

这里, x_p 是 x 在决策边界上的投影点, r 是到决策面边界的代数距离, w 与 $x - x_p$ 共线 (平行)。由于 $g(x_p) = w^t x_p + w_0 = 0$, 故有

$$g(x) = w^t x + w_0 = w^t (x_p + r w / \|w\|) + w_0 = r \|w\|$$

这样, $g(x)$ 的绝对值越大, 则点 x 距离决策边界越远



多类情况下的线性判别函数

若样本类别数在2类以上时，有两种构造线性判别函数的方法：

- ① 学习并构造出划分每一个类与其它类样本的线性函数
- ② 学习并构造出划分每两个不同的样本类的划分函数

若样本类数为 c ，则在第一种情况下，共有 c 个划分函数；
而在第二种情况下，共有 $c(c-1)/2$ 个划分函数。

➤ 在上述两种情况下，在特征空间中都存在无法确定测试样本类型的不确定区域



多类情况下：决策边界、特征空间的不确定区域

对于 4 类问题的线性决策边界。

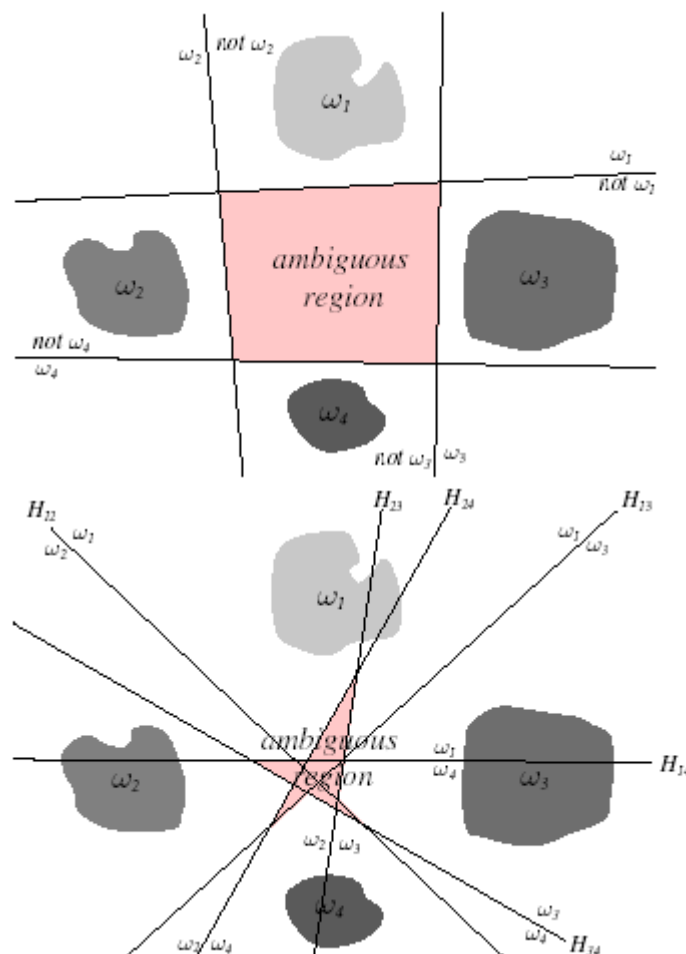
上面的图表示了采用

$\omega_i / \sim \omega_i$ 二分方法的结果；

下面的图表示了采用

ω_i / ω_j 二分方法的结果对应的
决策边界为 H_{ij} 。

图中的粉红色区域是类的类型
不确定的区域。



线性分类机

为了避免在特征空间中出现不确定的区域，可以采用线性分类机：

定义 c 个线性函数，将取得最大值的那个函数所在的类作为 \mathbf{x} 的类

$$g_k(\mathbf{x}) = \mathbf{w}_k^t \mathbf{x} + w_{k0} \quad k = 1, \dots, c$$

即若 $g_i(\mathbf{x}) > g_j(\mathbf{x}), \quad \forall j \neq i$ ，则将 \mathbf{x} 归类为 ω_i 类。

我们将这种情况下的分类器称为“**线性分类机**”。

- 线性分类机将特征空间划分为 c 个决策区域，并且若 \mathbf{x} 处在区域 R_i 中， $g_i(\mathbf{x})$ 的判决值取得最大值。对于两个邻近的区域 R_i 和 R_j ，其划分边界是超平面 H_{ij} 的一部分，其定义为

$$g_i(\mathbf{x}) = g_j(\mathbf{x})$$

$$\Leftrightarrow (\mathbf{w}_i - \mathbf{w}_j)^t \mathbf{x} + (w_{i0} - w_{j0}) = 0$$


$$\Leftrightarrow \mathbf{w}_i - \mathbf{w}_j \text{ 是 } H_{ij} \text{ 的法线, 且}$$

$$d(\mathbf{x}, H_{ij}) = \frac{g_i - g_j}{\|\mathbf{w}_i - \mathbf{w}_j\|}$$



线性分类机的决策边界

- 下图是对于3类和5类的问题，由学习分类机产生的决策边界



线性分类机的特点

- 易证:

线性分类机的决策区域是凸的，
这一约束限制了分类器的适应性和准确性。



广义线性判决函数

- 线性判别函数 $g(\mathbf{x})$ 可以写为:

$$g(x) = w_0 + \sum_{i=0}^d w_i x_i$$

其中, d 是特征空间的维数.

- 可以通过附加的项, 获得二次型的判别函数:

$$g(x) = w_0 + \sum_{i=0}^d w_i x_i + \sum_{i=0}^d \sum_{j=0}^d w_{ij} x_i x_j$$

- 二次判别函数通过分量之间的乘积, 可以引入 $d(d-1)/2$ 个系数。可以产生更复杂的曲面（二次曲面）。



广义线性判别函数

广义判别函数一般形式为：

$$g(x) = \sum_{i=0}^{d'} a_i y_i(x) \quad \text{或} \quad g(x) = \mathbf{a}^t \mathbf{y}$$

上述是所有 $y_i(\mathbf{x})$ 函数之加权和。 $y_i(\mathbf{x})$ 函数也称为 φ 函数。

可以看出，上面的和式并不是 \mathbf{x} 的线性函数，但却是 $y_i(\mathbf{x})$ 的线性函数。


$y_i(\mathbf{x})$ 函数的作用是将 d -维 \mathbf{x} -空间映射到 d' -维的 \mathbf{y} -空间。

例如： $g(\mathbf{x}) = a_1 + a_2 \mathbf{x} + a_3 \mathbf{x}^2$ $\mathbf{y} = (1 \quad \mathbf{x} \quad \mathbf{x}^2)^t$



特征空间的非线性映射: Figure5.5

- 映射 $\mathbf{y} = (1, \mathbf{x}, \mathbf{x}^2)^t$ 将一条直线变换为3维空间中的抛物线。
- 图中, 用一个平面将映射得到的 \mathbf{y} -空间分隔为相应的两类。而这在原始的1维 \mathbf{x} -空间中, 无法得到单连通的决策区域



对特征空间映射的几点说明

从 \mathbf{x} -空间到 \mathbf{y} -空间的映射:

- 若 \mathbf{x} 服从某一个确定的概率分布，则对应的分布在新的空间中一般是退化的。
 - 当新空间的维数高于原空间时，原分布在新空间中除对应曲线或曲面上的点外，其他地方均为0。
- 即使在 \mathbf{y} 空间中简单的判决函数，在 \mathbf{x} 空间中一般也是相当复杂的。
 - 空间的维数越高，其自由度越大（可描述的参数越多）。这样，就需要更多的学习样本。



特征空间的高维映射: Figure 5.6

- 一个2维输入空间 \mathbf{x} 通过多项式 f 映射为空间 \mathbf{y} 。

这里, $(y_1, y_2, y_3) = (x_1, x_2, x_1x_2)$ 。

- 在变换空间中, 线性判别式是一个分隔曲面的超平面。超平面正侧的点对应于类 ω_1 , 而下面的点对应于类 ω_2 。
- 而在空间 \mathbf{x} 中, R_1 不是单连通的。

