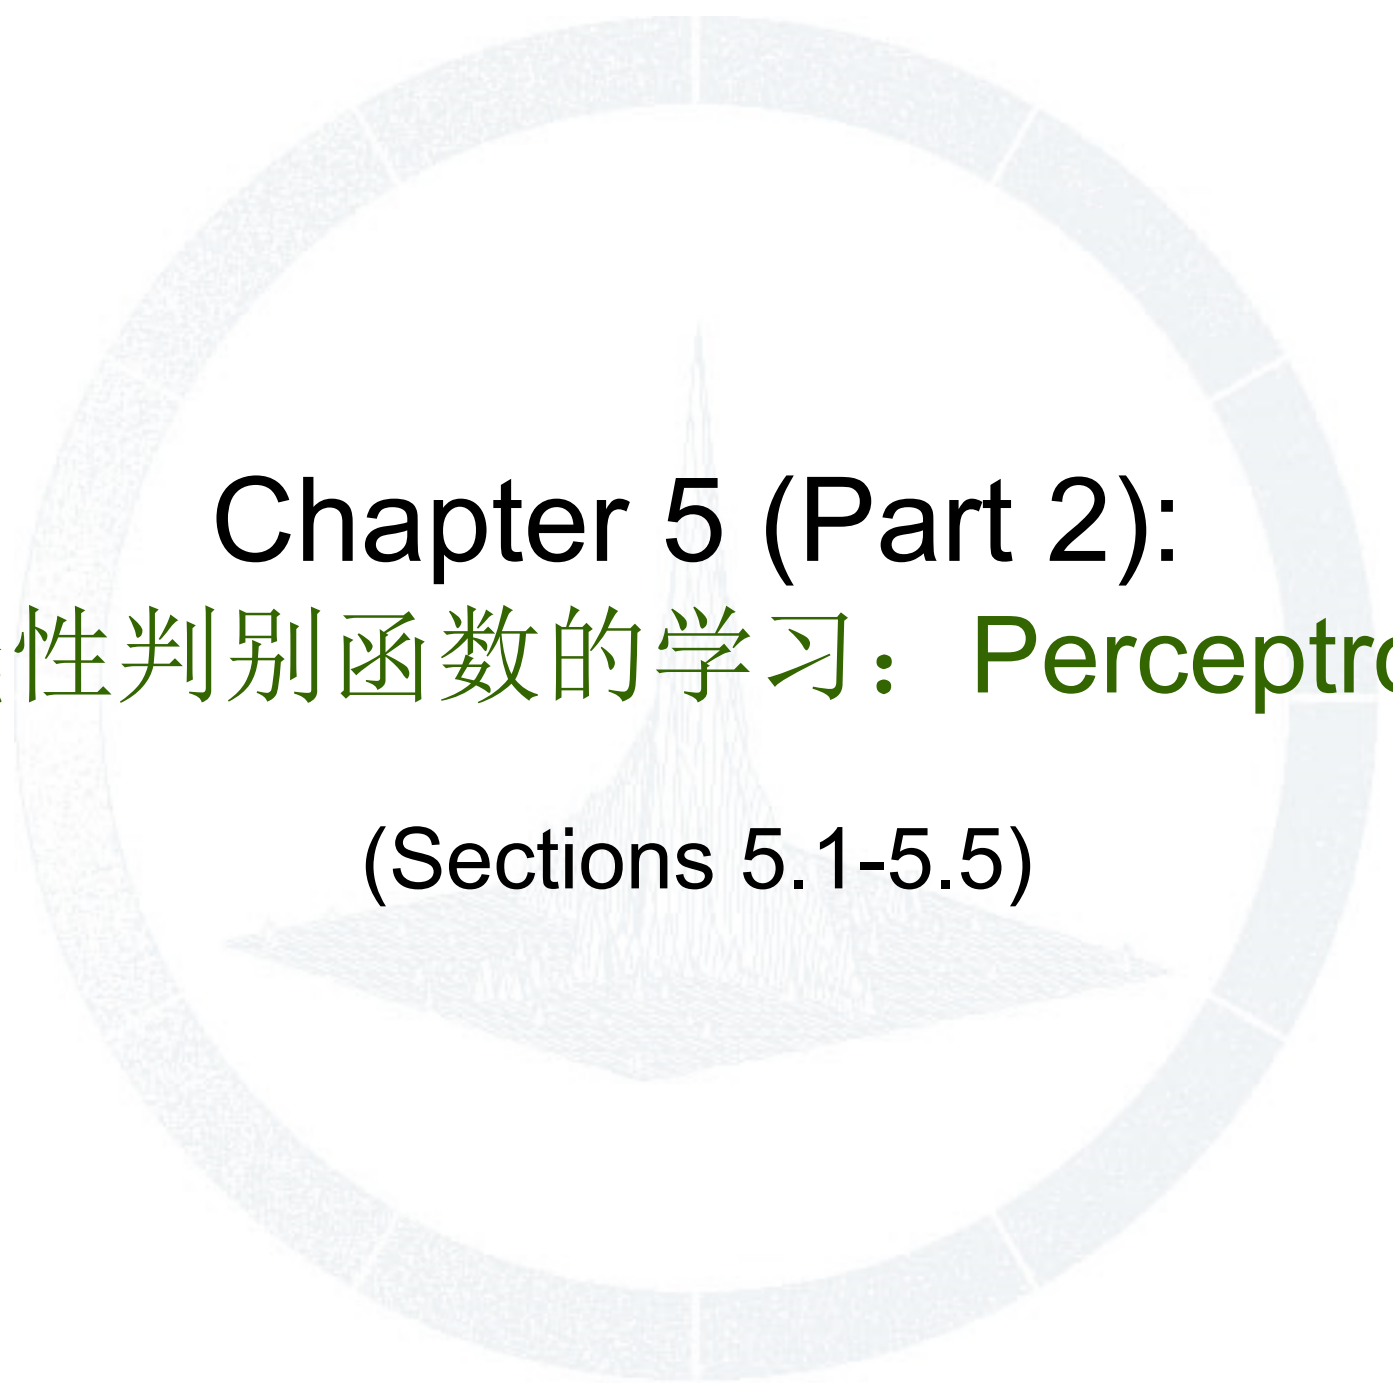




# 模式识别的理论与方法

## Pattern Recognition

裴继红



# Chapter 5 (Part 2):

## 线性判别函数的学习: Perceptron

(Sections 5.1-5.5)

# 本讲内容

- 两类线性可分情况的解
- 线性分类器的实现模型：感知器
- 权空间
- 准则函数与感知器的学习
- 感知器的学习算法
- 松弛算法
- 不可分情况的处理



# 两类线性可分情况的解

现在假设有  $n$  个样本  $y_1, y_2, \dots, y_n$ ，分为两类  $c_1$  和  $c_2$ 。

我们的目的是找出下面判别函数的权矢量  $\mathbf{a}$ ：

$$g(x) = \sum_{i=1}^n a_i y_i(x) = \mathbf{a}^t \mathbf{y}$$

若存在一个矢量  $\mathbf{a}^t$ ，在代入  $g(x)$  后可以将所有不同类的样本分开，我们称该问题是线性可分的。例如，

若  $y_i$  属于  $c_1$  类时有  $\mathbf{a}^t \mathbf{y}_i > 0$ ，或  $y_i$  属于  $c_2$  类时  $\mathbf{a}^t \mathbf{y}_i < 0$ ，则称  $y_i$  被正确分类了。


若对所有属于  $c_2$  类的  $y_i$  乘以一个负号，则只需要找出使所有样本的  $\mathbf{a}^t \mathbf{y}_i > 0$  的矢量  $\mathbf{a}^t$ ，

该矢量  $\mathbf{a}^t$  就是解矢量。



# 线性分类器的实现模型

——单层人工神经网络：感知器模型

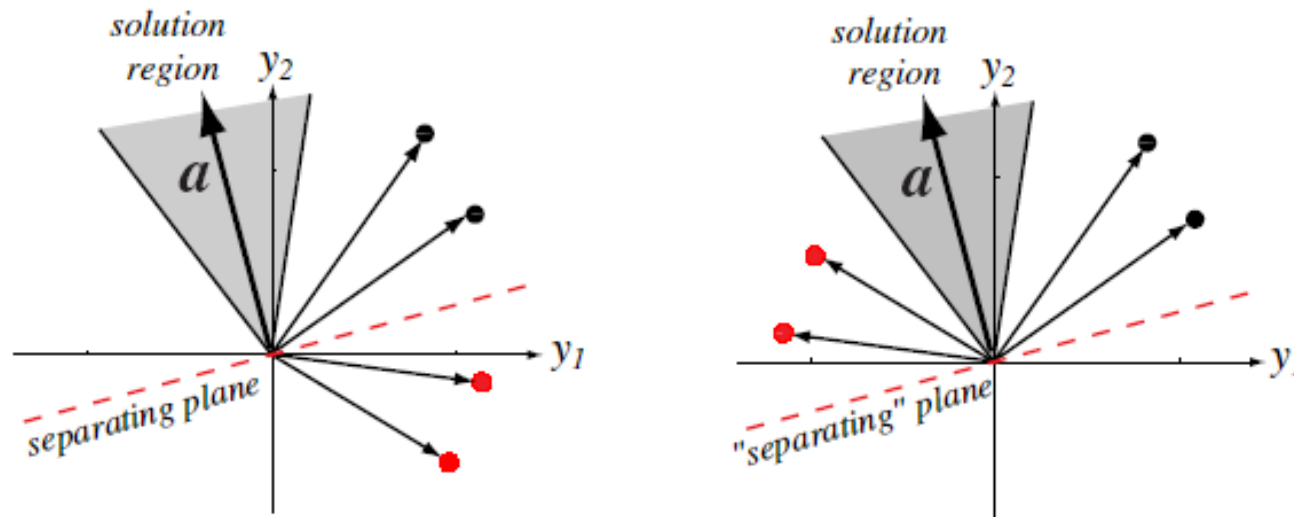


$$o(x_1, \dots, x_n) = \begin{cases} 1 & \text{if } w_0 + w_1 x_1 + \dots + w_n x_n > 0 \\ -1 & \text{otherwise.} \end{cases}$$




## Figure 5.8: 权空间的几何解释

- 4个训练样本(黑色属于 $\omega_1$ , 红色属于 $\omega_2$ )及其在特征空间的解域。
  - 在左面的图中使用的原始数据, 解向量导出的分类面将模式分为2类。
  - 在右图中, 红色的点经过了“规范化”——改变了矢量值的符号, 这样, 解向量导出的平面只需要将规范后的样本点划分到平面的同一侧。



# 解空间中边界裕量的作用: Figure5.9

- 左面是没有边界裕量( $b=0$ )的解空间,
- 右面是边界裕量  $b > 0$  的解空间, 解区域的边界缩小了  $b/\|y_i\|$ 。
- 边界裕量的存在提高了对新样本的分类性能



# 线性分类决策面的求解

即求解满足下面线性不等式方程的解：

$$\mathbf{a}^t \mathbf{y}_i > 0$$

该问题的解可以使用梯度下降技术求解。





# 求解优化问题的梯度下降技术

## 基本思想及步骤:

1. 定义一个准则函数（能量函数、误差函数）  $J(\mathbf{a})$
2. 令  $k = 1$ ;
3. 选取任意的初始解矢量  $\mathbf{a}$  值，记为  $\mathbf{a}(k)$ .
4. 计算  $J(\mathbf{a}(k))$  的梯度:  $\nabla J(\mathbf{a}(k))$
5. 沿梯度的负方向计算  $\mathbf{a}(k+1)$  ,  
(梯度的负方向是梯度最陡下降的方向).

一般地: 
$$\mathbf{a}(k+1) = \mathbf{a}(k) - \eta(k) \nabla J(\mathbf{a}(k))$$

这里， $\eta$  称为学习速率。



## 感知器准则函数1——误分类样本代数度量

求解下面不等式的可行的准则函数

$$\mathbf{a}^t \mathbf{y}_i > 0$$

可以仅仅简单地选择误分类的样本数。

此即为感知器准则函数：

$$J_p(\mathbf{a}) = \sum_{\mathbf{y} \in \Upsilon} (-\mathbf{a}^t \mathbf{y})$$

这里，和式是对所有被矢量  $\mathbf{a}$  误分的样本求和。



# 感知器学习

注意到  $\nabla J_p(a) = \sum_{y \in Y} (-y)$

因此，权矢量的更新规则变为：

$$a(k+1) = a(k) + \eta(k) \sum_{y \in Y} y$$

这里，和式是对所有被矢量  $a(k)$  误分的样本求和。  
学习规则总结如下：

新的权矢量 = 当前权矢量  
+ 被当前权矢量误分的所有样本之和  $\times$  学习因子



## 准则函数2——模式错分总数

令样本集合为Y，则模式错分总数的准则函数可表示为

$$J_E(a) = \frac{1}{2} \sum_{\mathbf{y} \in Y} (1 - \text{sign}(\mathbf{a}^t \mathbf{y}))$$

上式中， $\text{sign}(\cdot)$ 为符号函数



## 准则函数3——误差平方和

令样本集合为 $\mathbf{Y}$ ，则误差平方和准则函数可表示为

$$J_E(a) = \sum_{\mathbf{y} \in Y_E} (\mathbf{a}^t \mathbf{y})^2$$

上式中， $\mathbf{Y}_E$ 为错分样本集合



## 准则函数4——带边界裕量的误差平方和

令样本集合为 $Y$ ,

则带边界裕量的误差平方和准则函数可表示为

$$J_{E_2}(a) = \sum_{\mathbf{y} \in Y_E} (\mathbf{a}^t \mathbf{y} - b)^2$$

上式中,  $Y_E$ 为错分样本集合,  $b > 0$ 为边界裕量



# 不同准则下的解区域: Figure 5.11

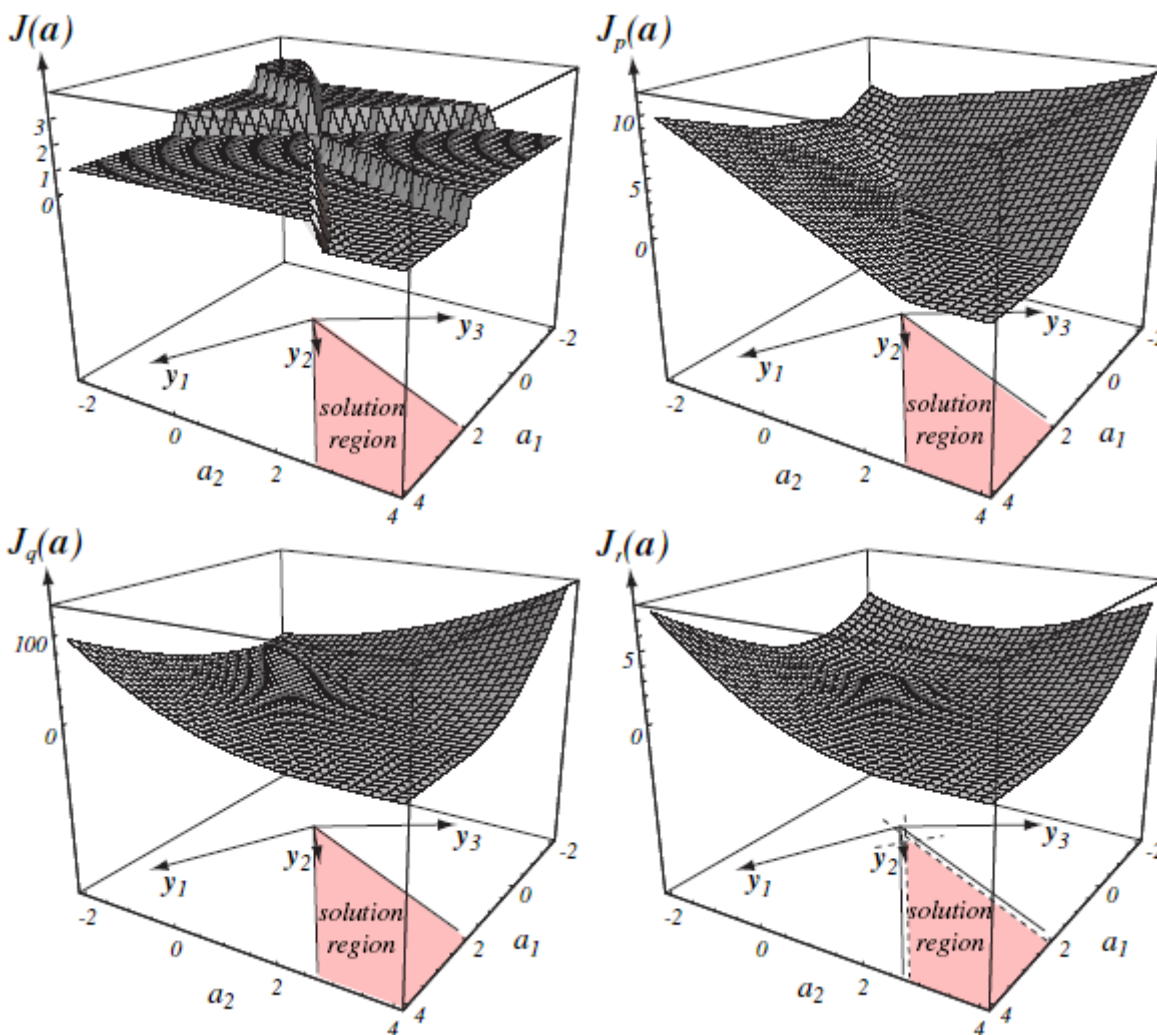
- 图中给出了在线性分类器中的4种学习准则在权空间的曲面。

左上图, **模式错分的总数**, 是分段常数曲面, 不适合梯度下降法。

右上图, **感知器准则 (Eq. 16)**, 是分段线性函数曲面, 可以采用梯度下降法。

左下图, **平方误差函数 (Eq. 32)**, 具有很好的解析特性, 即使在模式类线性不可分的情况下也可以使用。

右下图, **带有边界裕量的平方误差函数 (Eq. 33)**, 设计者可以通过调整边界裕量 $b$ 使得解矢量处于 $b = 0$ 的解区域的中部, 这样可以改善得到的分类器的推广性能



# 学习速率 $\eta$

学习速率  $\eta$  是梯度下降技术中的关键参数。

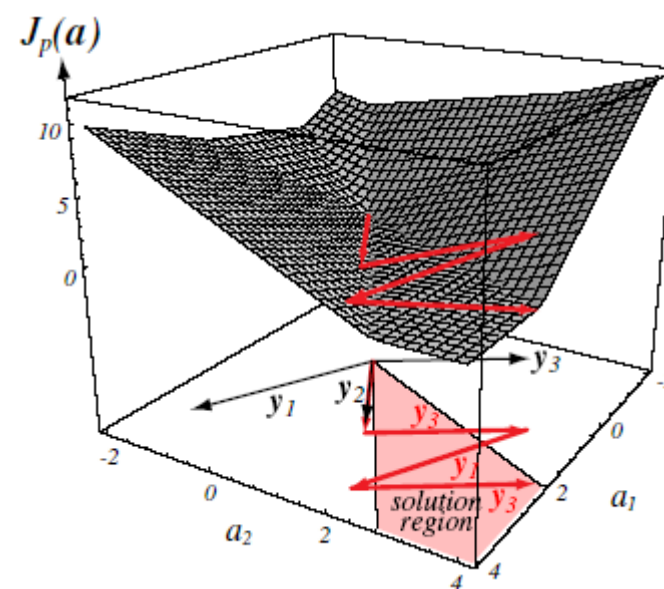
- a. 若 $\eta$  太小，则收敛到解时计算的步数太多，收敛时间太长。
- b. 若 $\eta$  太大，则容易引起“过冲”，不易收敛到最优点。





# 权向量的学习、过冲举例：Figure5.12

- 如图是 3 个样本的感知器学习过程。图中作为 权系数  $a_1$  和  $a_2$  的函数，画出了感知器准则函数， $J_p(a)$ ，的曲面。
- 权矢量的初始值为  $\mathbf{0}$ 。随着算法的进行，将错分模式点的规范化矢量相继加到权矢量上。
- 图中给出了以  $y_2, y_3, y_1, y_3$  为次序进行权矢量修正的过程。最后权矢量落在解区域，迭代结束。
- 注意，第二次更新中 (通过  $y_3$ )，解矢量比第一次更新后的解距离解区域更远了。



# 感知器学习算法- 1 :

## ——批处理感知器算法

算法的实现步骤:

1. 初始化: 权矢量  $\mathbf{a}$ , 学习步长  $\eta(\cdot)$ , 误差阈值  $\theta$ , 令  $k = 0$
2.     do  $k = k + 1$
3.          $\mathbf{a}(k + 1) = \mathbf{a}(k) + \eta(k) \sum_{y \in Y_k} y$
4.     while  $\left| \eta(k) \sum_{y \in Y_k} y \right| > \theta$
5.     Return  $\mathbf{a}$
6.     结束

- 算法的特点



# 感知器学习算法- 2 :

## ——固定增量单样本感知器算法

算法的实现步骤: (训练样本已经过规范化)

1. 初始化: 权矢量  $\mathbf{a}$ , 学习步长  $\eta(\cdot)$ , 误差阈值  $\theta$ , 令  $k = 0$
2.       do  $k = (k+1) \bmod n$    ( $n$ 为样本总数)
3.                  $\mathbf{a}(k+1) = \mathbf{a}(k) - y(k) \cdot (\text{sign}[\mathbf{a}^t y(k)] - 1) / 2$
4.       while 存在  $y(k) < 0, k=1, 2, \dots, n$
5.     Return  $\mathbf{a}$
6.     结束

- 算法的特点



# 感知器学习算法-3:

## ——带裕量的单样本感知器算法

算法的实现步骤：（训练样本已经过规范化）

1. 初始化：权矢量  $\mathbf{a}$ ，裕量  $b$ ， $\eta(\cdot)$ ，误差阈值  $\theta$ ，令  $k = 0$
2.       do  $k = (k+1) \bmod n$    ( $n$ 为样本总数)
3.              $\mathbf{a}(k+1) = \mathbf{a}(k) - \eta(k) \cdot y(k) \cdot (\text{sign}[\mathbf{a}^t y(k) - b] - 1) / 2$
4.       while 存在  $\mathbf{a}^t y(k) < b$  ,  $k=1, 2, \dots, n$
5.     Return  $\mathbf{a}$
6. 结束

- 算法的特点



# 感知器算法的松弛过程

以前的准则函数  $J(.)$  定义为:

$$J_p(\mathbf{a}) = \sum_{\mathbf{y} \in Y} \mathbf{a}^t \mathbf{y}$$

上面准则函数的**问题**为:

1. 该函数过于平滑。解矢量很可能正好落在边界上.
2. 函数的解在很大程度上受到模值大的样本的支配

感知器规则可以被推广为 “松弛过程” .



## 准则函数4——松弛算法

感知器松弛算法是对下面函数进行求解:

$$J_r(\mathbf{a}) = \frac{1}{2} \sum_{\mathbf{y} \in Y} \frac{(\mathbf{a}^t \mathbf{y} - b)^2}{\|\mathbf{y}\|^2}$$

这里, 是对所有满足下面关系的样本集合进行求和:

$$\mathbf{a}^t \mathbf{y} \leq b$$

上面的准则函数总是非负。当且仅当在所有  $\mathbf{a}^t \mathbf{y} > b$  时, 函数值为0



# 松弛算法：梯度、迭代公式

➤ 准则函数的梯度

$$\nabla J_r = \sum_{y \in Y} \frac{a^t y - b}{\|y\|^2} y$$

➤ 批处理裕量迭代公式

$$a(k+1) = a(k) + \eta(k) \sum_{y \in Y} \frac{a^t y - b}{\|y\|^2} y$$

➤ 单样本裕量迭代公式

$$a(k+1) = a(k) + \eta(k) \frac{a^t y(k) - b}{\|y(k)\|^2} y(k)$$



## 松弛算法的实质

- 使用规范化样本进行学习，即学习中主要利用**样本在特征空间的方向信息**进行学习

$$\nabla J_r = \sum_{y \in Y} \frac{a^t y - b}{\|y\|^2} y = \sum_{y \in Y} \left( \frac{a^t y - b}{\|y\|} \cdot \frac{y}{\|y\|} \right)$$

$$a(k+1) = a(k) + \eta(k) \sum_{y \in Y} \left( \frac{a^t y - b}{\|y\|} \cdot \frac{y}{\|y\|} \right)$$

$$a(k+1) = a(k) + \eta(k) \frac{a^t y(k) - b}{\|y(k)\|} \cdot \frac{y(k)}{\|y(k)\|}$$





# 感知器算法：不可分的情况的处理

感知器准则对线性可分情况是有效的，可以寻找到一个无错误的解。

在针对线性不可分问题时，一个解决的办法是使用可变学习率

$\eta(k)$  在  $k$  趋近于无穷时，可以令其逐渐趋近于0.

具体做法为:

- 在性能改善时，逐渐减小  $\eta(k)$

例如可以定义一个函数：  $\eta(k) = \eta(1)/k$

